

Politechnika Warszawska

WYDZIAŁ ELEKTRONIKI
I TECHNIK INFORMACYJNYCH



Przedmiot:
Pracownia Dyplomowa Inżynierska 1



Rozpoznawanie trików deskorolkowych w aplikacji mobilnej z funkcją mapowania skateparków

Wstęp do pracy inżynierskiej
Jan Błoniarz

Prowadzący:
dr. inż. Tomasz Mrozek

Data: 4 czerwca 2025

Spis treści

1	Wstęp	2
1.1	Opis pracy	2
1.2	Proponowane zadania na semestr	2
1.2.1	Przegląd istniejących aplikacji mobilnych dla społeczności deskorolkowej i systemów do rozpoznawania aktywności fizycznych	2
1.2.2	Projekt architektury aplikacji mobilnej do rozpoznawania trików deskorolkowych i mapowania skateparków	2
1.2.3	Przegląd i wybór technologii do implementacji aplikacji mobilnej oraz rozwiązań AI do analizy trików deskorolkowych	2
1.2.4	Analiza potencjalnych źródeł danych treningowych do modelu AI rozpoznającego triki deskorolkowe	2
2	Realizacja	3
2.1	Przegląd istniejących aplikacji mobilnych dla społeczności deskorolkowej i systemów do rozpoznawania aktywności fizycznych	3
2.1.1	Skatespots	3
2.1.2	FindSkateSpots.com	3
2.1.3	Skatespot	3
2.1.4	Google MoveNet	3
2.1.5	OpenPose	3
2.1.6	Wnioski	3
2.2	Projekt architektury aplikacji mobilnej do rozpoznawania trików deskorolkowych i mapowania skateparków	3
2.2.1	Architektura systemu	3
2.2.2	Funkcjonalności aplikacji	4
2.3	Przegląd i wybór technologii do implementacji aplikacji mobilnej oraz rozwiązań AI do analizy trików deskorolkowych	5
2.3.1	Frontend aplikacji mobilnej	5
2.3.2	Backend i API	5
2.3.3	Baza danych	5
2.3.4	Mapy i geolokalizacja	5
2.3.5	Technologie do analizy trików deskorolkowych	5
2.4	Analiza potencjalnych źródeł danych treningowych do modelu AI rozpoznającego triki deskorolkowe	5
2.4.1	Istniejące otwarte zbiory danych	5
2.4.2	Pozyskiwanie danych z platform społecznościowych	6
2.4.3	Wstępna koncepcja struktury danych treningowych	6

1 Wstęp

1.1 Opis pracy

Głównym celem pracy inżynierskiej jest stworzenie platformy mobilnej dla społeczności deskorolkowej, która analizowałaby nagrania trików deskorolkowych i automatycznie nazywałaby je, oceniała poprawność wykonania i zapisywałaby nagrania użytkownika. Dodatkowo w aplikacji znajdować będzie się mapa skateparków, którą użytkownicy mogliby poszerzać o zdjęcia oraz informacje o przeszkodach, stanie skateparku i innych czynnikach. Aplikacja miałaby na celu wspieranie rozwoju społeczności, umożliwiając jej członkom śledzenie postępów oraz lokalizowanie skateparków.

1.2 Proponowane zadania na semestr

1.2.1 Przegląd istniejących aplikacji mobilnych dla społeczności deskorolkowej i systemów do rozpoznawania aktywności fizycznych

Należy znaleźć i opisać istniejące aplikacje mobilne skierowane do społeczności deskorolkowej, zwracając uwagę na funkcje społecznościowe, mapowanie, analizę trików i nagrań wideo. Dodatkowo zidentyfikować istniejące systemy do rozpoznawania aktywności fizycznych — np. w sportach ekstremalnych, tanecznych lub fitnessowych — i dokonać ich przeglądu. Wskazać możliwości wykorzystania takich rozwiązań w deskorolce. Opisać wady i zalety oraz wskazać braki, które aplikacja inżynierska mogłaby uzupełnić.

1.2.2 Projekt architektury aplikacji mobilnej do rozpoznawania trików deskorolkowych i mapowania skateparków

Opracowanie koncepcji aplikacji: przedstawienie planowanych modułów funkcjonalnych (rozpoznawanie trików z filmów, mapa skateparków, profil użytkownika, system ocen i postępów), określenie typów użytkowników (zalogowani, niezalogowani, administratorzy), opis interfejsu, przepływu danych, propozycja ekranów oraz interakcji użytkownika. Uwzględnić również architekturę backendu i komunikację z serwerem oraz AI.

1.2.3 Przegląd i wybór technologii do implementacji aplikacji mobilnej oraz rozwiązań AI do analizy trików deskorolkowych

Dobór stosu technologicznego frontend (np. Flutter vs React Native), backend (np. FastAPI), bazy danych (np. PostgreSQL, Firebase), map (Google Maps API vs OpenStreetMap), a także technologii do analizy trików (np. TensorFlow Lite, MediaPipe, analiza klatek wideo). Uzasadnienie wyborów na podstawie wymagań projektu, łatwości integracji, dostępności bibliotek oraz możliwości wdrożenia na urządzeniach mobilnych.

1.2.4 Analiza potencjalnych źródeł danych treningowych do modelu AI rozpoznającego triki deskorolkowe

Identyfikacja otwartych lub możliwych do pozyskania źródeł nagrań trików, np. YouTube, Instagram, TikTok, fora deskorolkowe, repozytoria open source. Ocena jakości nagrań, ich etykietowania oraz możliwości wykorzystania ich do trenowania modelu AI. Wstępna koncepcja struktury danych treningowych

2 Realizacja

2.1 Przegląd istniejących aplikacji mobilnych dla społeczności deskorolkowej i systemów do rozpoznawania aktywności fizycznych

Na rynku istnieje kilka aplikacji mobilnych dedykowanych społeczności deskorolkowej, które oferują różnorodne funkcje wspierające zarówno początkujących, jak i zaawansowanych użytkowników.

2.1.1 Skatespots

SkateSpots[1] to aplikacja umożliwiająca użytkownikom wyszukiwanie i udostępnianie miejsc do jazdy na deskorolce. Użytkownicy mogą dodawać zdjęcia, opisy oraz informacje o przeszkodach i stanie nawierzchni. Aplikacja posiada również funkcje społecznościowe, takie jak komentowanie i ocenianie miejsc. Aplikacja nie ma funkcji rozpoznawania trików deskorolkowych i nie jest popularna w Polsce.

2.1.2 FindSkateSpots.com

Jest to strona internetowa[2] poświęcona miejscom do jeżdżenia na deskorolce, działa podobnie jak Skatespots, ale w formie strony internetowej. Jest użytkowana przez niewielu użytkowników, przede wszystkim ze Stanów Zjednoczonych. Z punktu widzenia użytkownika, aplikacja mobilna wydaje się być wygodniejszym sposobem na zdobywanie tych informacji dla przeciętnego deskorolkarza.

2.1.3 Skatespot

Jest to strona internetowa[3] poświęcona znajdowaniu skateparków oraz śledzeniu aktywności fizycznej. Nie została spopularyzowana wśród społeczności deskorolkowej.

2.1.4 Google MoveNet

MoveNet[4] to model opracowany przez Google, przeznaczony do szybkiego i dokładnego wykrywania pozycji ciała w czasie rzeczywistym. Może śledzić do 17 punktów na ciele człowieka i jest wykorzystywany w aplikacjach fitness, jogi czy tanecznych, zapewniając niskie opóźnienie i wysoką precyzję nawet na urządzeniach mobilnych. Dzięki tym cechom MoveNet mógłby zostać zaadaptowany do rozpoznawania ruchów i trików deskorolkowych.

2.1.5 OpenPose

OpenPose[5] to jeden z pierwszych systemów open-source do analizy postawy ciała w czasie rzeczywistym, opracowany przez Carnegie Mellon University. Umożliwia wykrycie szkieletu ciała człowieka, dłoni oraz twarzy z materiałów wideo lub zdjęć. Jest szeroko stosowany w badaniach naukowych oraz aplikacjach sportowych i tanecznych. Jego dokładność i możliwość przetwarzania wielu osób jednocześnie czyni go użytecznym narzędziem również dla analizy trików deskorolkowych.

2.1.6 Wnioski

Analiza istniejących aplikacji i systemów wskazuje na brak kompleksowego rozwiązania dedykowanego społeczności deskorolkowej, które łączyłoby mapowanie miejsc oraz analizę trików z wykorzystaniem sztucznej inteligencji. Proponowana aplikacja inżynierska mogłaby wypełnić tę lukę, oferując użytkownikom narzędzie do śledzenia postępów, lokalizowania skateparków oraz automatycznej analizy wykonanych trików.

2.2 Projekt architektury aplikacji mobilnej do rozpoznawania trików deskorolkowych i mapowania skateparków

2.2.1 Architektura systemu

- Aplikacja mobilna

- umożliwia użytkownikowi nagrywanie trików deskorolkowych oraz ich późniejszy podgląd i ocenę,
- zawiera interaktywną mapę skateparków z możliwością przeglądania i dodawania informacji o przeszkodach,
- dane (np. filmy, lokalizacje, historia użytkownika) przechowywane są lokalnie, co pozwala na działanie aplikacji w trybie offline,

- aplikacja synchronizuje dane z serwerem, gdy połączenie internetowe jest dostępne.

- **Warstwa serwerowa (backend)**

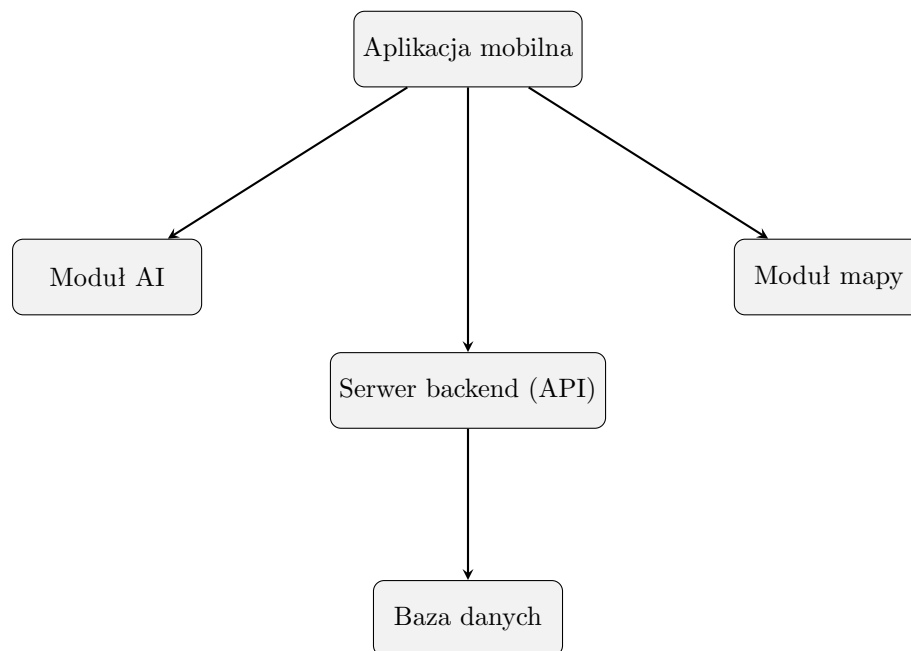
- udostępnia REST API do komunikacji z aplikacją mobilną,
- centralna baza danych gromadzi informacje o użytkownikach, nagraniach, wynikach analizy trików oraz lokalizacjach skateparków,
- backend wspiera działanie mechanizmów analizy, historii postępów oraz zarządzania treściami dodawanymi przez społeczność.

- **Moduł rozpoznawania trików**

- komponent odpowiedzialny za analizę przesłanych nagrań wideo i klasyfikację wykonanych trików przy użyciu sztucznej inteligencji,
- model AI działa lokalnie lub w chmurze – w zależności od konfiguracji i dostępnych zasobów urządzenia mobilnego.

- **System mapy skateparków**

- zawiera otwartą mapę z lokalizacjami skateparków, które użytkownicy mogą rozbudowywać,
- do każdej lokalizacji można przypisać opisy przeszkód, zdjęcia i komentarze.



Rysunek 1: Schemat architektury systemu

2.2.2 Funkcjonalności aplikacji

- analiza nagrania wideo w celu wykrycia i sklasyfikowania triku deskorolkowego,
- przypisanie wykrytych trików do profilu użytkownika oraz zapis w historii postępów,
- dodawanie lokalizacji skateparku przez użytkowników wraz ze zdjęciami i informacjami o przeszkodach,
- przeglądanie mapy skateparków z możliwością filtrowania po lokalizacji i typie przeszkód,
- tworzenie i edycja profilu użytkownika z informacjami o umiejętnościach oraz historii trików,
- raportowanie postępów użytkownika na podstawie liczby i jakości wykonanych trików,
- zapis lokalny danych i nagrań w przypadku braku połączenia z siecią (tryb offline),
- synchronizacja danych z serwerem po przywróceniu połączenia z internetem.

2.3 Przegląd i wybór technologii do implementacji aplikacji mobilnej oraz rozwiązań AI do analizy trików deskorolkowych

2.3.1 Frontend aplikacji mobilnej

Do stworzenia interfejsu użytkownika planowane jest wykorzystanie frameworka **Flutter**, który pozwoli na budowę aplikacji mobilnej działającej na Androidzie i iOS z jednej bazy kodu. Dzięki wysokiej wydajności, szerokiemu zestawowi komponentów oraz łatwej integracji z natywnymi funkcjami systemowymi (takimi jak kamera czy lokalizacja), Flutter powinien dobrze spełnić potrzeby aplikacji związane z rejestrowaniem trików i obsługą map skateparków.

2.3.2 Backend i API

Jako technologię backendową przewiduje się użycie **FastAPI**, nowoczesnego frameworka webowego w języku Python. Rozwiązanie to umożliwi szybkie tworzenie wydajnych i dobrze udokumentowanych interfejsów REST API oraz zapewni prostą integrację z bibliotekami do uczenia maszynowego, co będzie istotne przy analizie nagrań trików.

2.3.3 Baza danych

Do przechowywania danych planowane jest zastosowanie dwóch typów baz danych. W chmurze działałaby relacyjna baza **PostgreSQL**, odpowiednia do przechowywania danych o użytkownikach, skateparkach i wynikach analizy. W aplikacji mobilnej wykorzystywana będzie lokalna baza **SQLite**, która umożliwi pracę offline oraz późniejszą synchronizację danych z serwerem po odzyskaniu połączenia z siecią.

2.3.4 Mapy i geolokalizacja

W celu obsługi mapy skateparków planowane jest użycie otwartego systemu **OpenStreetMap**, zintegrowanego za pomocą biblioteki Flutter Map. Rozwiązanie to zapewni elastyczność, możliwość dostosowania mapy do potrzeb użytkowników oraz brak opłat licencyjnych, co będzie korzystne przy dalszym rozwoju projektu.

2.3.5 Technologie do analizy trików deskorolkowych

Moduł analizy trików ma wykorzystywać połączenie **MediaPipe** oraz **TensorFlow Lite**. MediaPipe dostarczy funkcjonalności detekcji pozycji ciała i śledzenia ruchu w czasie rzeczywistym, natomiast TensorFlow Lite umożliwi uruchamianie zoptymalizowanych modeli sztucznej inteligencji bezpośrednio na urządzeniach mobilnych. Planowana analiza będzie odbywać się lokalnie — poprzez ekstrakcję klatek z nagrania i klasyfikację sekwencji ruchów — co zredukuje potrzebę przesyłania dużych plików do chmury.

2.4 Analiza potencjalnych źródeł danych treningowych do modelu AI rozpoznającego triki deskorolkowe

Skuteczne rozpoznawanie trików deskorolkowych przez model AI wymaga dostępu do odpowiednio przygotowanych danych treningowych. W tym celu rozważane są zarówno istniejące otwarte zbiory danych, jak i możliwość pozyskania nowych materiałów z dostępnych źródeł.

2.4.1 Istniejące otwarte zbiory danych

Jednym z dostępnych zbiorów danych jest projekt **SkateboardML**[6], który zawiera nagrania wideo dwóch podstawowych trików: ollie i kickflip. Dane te zostały wykorzystane do trenowania modelu klasyfikującego te triki.

Innym przykładem jest projekt **SkateboardAI**[7], oferujący zbiór danych zawierający nagrania różnych trików deskorolkowych. Zbiór ten został wykorzystany do trenowania modeli rozpoznających triki w różnych warunkach.

Dodatkowo, projekt **skateboarding-trick-classifier**[8] udostępnia dane z akcelerometrów zamontowanych na deskorolce, rejestrujące sygnały podczas wykonywania różnych trików. Dane te mogą być wykorzystane do trenowania modeli rozpoznających triki na podstawie danych sensorycznych.

2.4.2 Pozyskiwanie danych z platform społecznościowych

Platformy takie jak YouTube, Instagram czy TikTok są bogatym źródłem nagrań trików deskorolkowych. Wiele z tych nagrań zawiera opisy lub hashtagi identyfikujące wykonane triki, co może ułatwić proces etykietowania danych. Pozyskiwanie danych z tych platform wymaga jednak uwzględnienia kwestii praw autorskich oraz prywatności. Konieczne jest uzyskanie odpowiednich zgód od twórców lub korzystanie z materiałów udostępnionych na licencjach pozwalających na ich wykorzystanie w celach badawczych.

2.4.3 Wstępna koncepcja struktury danych treningowych

Dane treningowe powinny być odpowiednio zorganizowane, aby umożliwić efektywne trenowanie modelu sztucznej inteligencji. Proponowana struktura danych obejmuje nagrania wideo przedstawiające pojedyncze triki deskorolkowe, zarejestrowane z różnych perspektyw oraz w różnych warunkach oświetleniowych. Każde nagranie powinno być opatrzone etykietą identyfikującą wykonany trik, a także dodatkowymi informacjami, takimi jak poziom trudności czy to, czy wykonanie było udane. Dodatkowo warto dołączyć metadane zawierające informacje o lokalizacji i czasie nagrania, użytym sprzęcie oraz parametrach technicznych materiału, takich jak liczba klatek na sekundę czy rozdzielczość. Taka struktura danych umożliwi trenowanie modeli AI zdolnych do skutecznego rozpoznawania i klasyfikowania trików deskorolkowych na podstawie analizy materiału wideo.

Literatura

- [1] Wikipedia contributors. Skatespots — wikipedia, the free encyclopedia. <https://en.wikipedia.org/wiki/Skatespots>, 2025. Dostęp zdalny (04.06.2025).
- [2] Findskatespots.com. <https://findskatespots.com>, 2025. Dostęp zdalny (04.06.2025).
- [3] Skatespot – find skate spots near you. <https://skatespot.com/home/>, 2025. Dostęp zdalny (04.06.2025).
- [4] Movenet: Ultra szybki i dokładny model wykrywania pozy. <https://www.tensorflow.org/hub/tutorials/movenet?hl=pl>, 2021. Dostęp zdalny (04.06.2025).
- [5] CMU Perceptual Computing Lab. Openpose. <https://github.com/CMU-Perceptual-Computing-Lab/openpose>, 2025. GitHub, dostęp zdalny (04.06.2025).
- [6] LightningDrop. Skateboardml. <https://github.com/LightningDrop/SkateboardML>, 2024. GitHub, dostęp zdalny (04.06.2025).
- [7] Nicolas Kluge Corrêa. Skateboarding trick classifier. <https://github.com/Nkluge-correa/skateboarding-trick-classifier>, 2023. GitHub, dostęp zdalny (04.06.2025).
- [8] GitHub user 2000222. Skateboard-ai. <https://github.com/2000222/Skateboard-AI>, 2023. GitHub, dostęp zdalny (04.06.2025).