

Politechnika Warszawska

WYDZIAŁ ELEKTRONIKI
I TECHNIK INFORMACYJNYCH



Instytut Zakład Systemów Telekomunikacyjnych

Praca dyplomowa inżynierska

na kierunku Inżynieria Internetu Rzeczy

Rozpoznawanie trików deskorolkowych w aplikacji mobilnej z funkcją
mapowania skateparków

Jan Błoniarz

Numer albumu 321007

promotor

dr inż. Tomasz Mrozek

WARSZAWA 2026

Rozpoznawanie trików deskorolkowych w aplikacji mobilnej z funkcją mapowania skateparków

Streszczenie. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetur id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

Nam dui ligula, fringilla a, euismod sodales, sollicitudin vel, wisi. Morbi auctor lorem non justo. Nam lacus libero, pretium at, lobortis vitae, ultricies et, tellus. Donec aliquet, tortor sed accumsan bibendum, erat ligula aliquet magna, vitae ornare odio metus a mi. Morbi ac orci et nisl hendrerit mollis. Suspendisse ut massa. Cras nec ante. Pellentesque a nulla. Cum sociis natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Aliquam tincidunt urna. Nulla ullamcorper vestibulum turpis. Pellentesque cursus luctus mauris.

Nulla malesuada porttitor diam. Donec felis erat, congue non, volutpat at, tincidunt tristique, libero. Vivamus viverra fermentum felis. Donec nonummy pellentesque ante. Phasellus adipiscing semper elit. Proin fermentum massa ac quam. Sed diam turpis, molestie vitae, placerat a, molestie nec, leo. Maecenas lacinia. Nam ipsum ligula, eleifend at, accumsan nec, suscipit a, ipsum. Morbi blandit ligula feugiat magna. Nunc eleifend consequat lorem. Sed lacinia nulla vitae enim. Pellentesque tincidunt purus vel magna. Integer non enim. Praesent euismod nunc eu purus. Donec bibendum quam in tellus. Nullam cursus pulvinar lectus. Donec et mi. Nam vulputate metus eu enim. Vestibulum pellentesque felis eu massa.

Słowa kluczowe: XXX, XXX, XXX

Skateboard trick recognition in a mobile application with skatepark mapping functionality

Abstract. As any dedicated reader can clearly see, the Ideal of practical reason is a representation of, as far as I know, the things in themselves; as I have shown elsewhere, the phenomena should only be used as a canon for our understanding. The paralogisms of practical reason are what first give rise to the architectonic of practical reason. As will easily be shown in the next section, reason would thereby be made to contradict, in view of these considerations, the Ideal of practical reason, yet the manifold depends on the phenomena. Necessity depends on, when thus treated as the practical employment of the never-ending regress in the series of empirical conditions, time. Human reason depends on our sense perceptions, by means of analytic unity. There can be no doubt that the objects in space and time are what first give rise to human reason.

Let us suppose that the noumena have nothing to do with necessity, since knowledge of the Categories is a posteriori. Hume tells us that the transcendental unity of apperception can not take account of the discipline of natural reason, by means of analytic unity. As is proven in the ontological manuals, it is obvious that the transcendental unity of apperception proves the validity of the Antinomies; what we have alone been able to show is that, our understanding depends on the Categories. It remains a mystery why the Ideal stands in need of reason. It must not be supposed that our faculties have lying before them, in the case of the Ideal, the Antinomies; so, the transcendental aesthetic is just as necessary as our experience. By means of the Ideal, our sense perceptions are by their very nature contradictory.

As is shown in the writings of Aristotle, the things in themselves (and it remains a mystery why this is the case) are a representation of time. Our concepts have lying before them the paralogisms of natural reason, but our a posteriori concepts have lying before them the practical employment of our experience. Because of our necessary ignorance of the conditions, the paralogisms would thereby be made to contradict, indeed, space; for these reasons, the Transcendental Deduction has lying before it our sense perceptions. (Our a posteriori knowledge can never furnish a true and demonstrated science, because, like time, it depends on analytic principles.) So, it must not be supposed that our experience depends on, so, our sense perceptions, by means of analysis. Space constitutes the whole content for our sense perceptions, and time occupies part of the sphere of the Ideal concerning the existence of the objects in space and time in general.

Keywords: XXX, XXX, XXX



.....
miejscowość i data

.....
imię i nazwisko studenta

.....
numer albumu

.....
kierunek studiów

OŚWIADCZENIE

Świadomy/-a odpowiedzialności karnej za składanie fałszywych zeznań oświadczam, że niniejsza praca dyplomowa została napisana przeze mnie samodzielnie, pod opieką kierującego pracą dyplomową.

Jednocześnie oświadczam, że:

- niniejsza praca dyplomowa nie narusza praw autorskich w rozumieniu ustawy z dnia 4 lutego 1994 roku o prawie autorskim i prawach pokrewnych (Dz.U. z 2006 r. Nr 90, poz. 631 z późn. zm.) oraz dóbr osobistych chronionych prawem cywilnym,
- niniejsza praca dyplomowa nie zawiera danych i informacji, które uzyskałem/-am w sposób niedozwolony,
- niniejsza praca dyplomowa nie była wcześniej podstawą żadnej innej urzędowej procedury związanej z nadawaniem dyplomów lub tytułów zawodowych,
- wszystkie informacje umieszczone w niniejszej pracy, uzyskane ze źródeł pisanych i elektronicznych, zostały udokumentowane w wykazie literatury odpowiednimi odnośnikami,
- znam regulacje prawne Politechniki Warszawskiej w sprawie zarządzania prawami autorskimi i prawami pokrewnymi, prawami własności przemysłowej oraz zasadami komercjalizacji.

Oświadczam, że treść pracy dyplomowej w wersji drukowanej, treść pracy dyplomowej zawartej na nośniku elektronicznym (płyce kompaktowej) oraz treść pracy dyplomowej w module APD systemu USOS są identyczne.

.....
czytelny podpis studenta

Spis treści

1. Wstęp	11
2. Przegląd istniejących rozwiązań	13
2.1. Aplikacje dedykowane dla społeczności deskorolkowej	13
2.2. Analiza ruchu w sporcie: Wideo a czujniki sprzętowe	16
2.3. Modele wizyjnej analizy ruchu	17
2.4. Podsumowanie	19
3. Założenia i architektura systemu	21
3.1. Wymagania funkcjonalne i нефункционалне	21
3.2. Wybór technologii	21
3.2.1. Podejście IoT (czujnikowe)	22
3.2.2. Podejście wizyjne (<i>Edge AI</i>)	23
3.3. Architektura systemu	24
4. Projekt interfejsu użytkownika	26
4.1. Założenia projektowe i makiety aplikacji	26
4.2. Nawigacja i główne ekrany aplikacji	26
4.2.1. Ekran mapy (<i>Spot Map</i>)	27
4.2.2. Ekran wykrywania trików (<i>Detect Trick</i>)	28
4.3. Interakcja użytkownika z modułem rozpoznawania trików	30
5. Opracowanie modułu sztucznej inteligencji	31
5.1. Zbiór danych treningowych	31
5.2. Ekstrakcja cech i estymacja pozy	32
5.3. Preprocessing i normalizacja danych	32
5.4. Architektura modelu klasyfikacyjnego	33
5.5. Trenowanie modelu i konwersja TensorFlow Lite	33
6. Budowa aplikacji mobilnej i warstwy serwerowej	35
6.1. Struktura projektu w środowisku Flutter	35
6.2. Integracja modułu mapy	35
6.3. Obsługa kamery i zarządzanie plikami wideo	36
6.4. Integracja modułu TensorFlow Lite z aplikacją	38
6.4.1. Estymacja pozy	38
6.4.2. Klasyfikacja ewolucji	38
6.5. Architektura i implementacja warstwy serwerowej	40
6.6. Baza danych oraz przechowywanie zasobów multimedialnych	41
6.7. Finalny wygląd aplikacji	43
7. Testy oraz analiza wyników	44
7.1. Środowisko i scenariusze testowe	44
7.2. Ewaluacja skuteczności modelu SI	44

7.3. Testy funkcjonalne aplikacji	44
7.4. Podsumowanie	44
7.4.1. Napotkane trudności	44
7.4.2. Wdrożone poprawki	44
8. Podsumowanie	45
8.1. Wnioski z przeprowadzonych prac	45
8.2. Ograniczenia stworzonego rozwiązania	45
8.3. Możliwości dalszego rozwoju	45
Spis rysunków	47
Spis tabel	48
Spis załączników	49

Wykaz symboli i skrótów

EiTI – Wydział Elektroniki i Technik Informatycznych

PW – Politechnika Warszawska

WEIRD – ang. *Western, Educated, Industrialized, Rich and Democratic*

UI/UX – ang. *User Interface/User Experience*

SI – Sztuczna Inteligencja

AI – ang. *Artificial Intelligence*

IoT – ang. *Internet of Things*

IMU – ang. *Inertial Measurement Unit*

HAR – ang. *Human Action Recognition*

CNN – ang. *Convolutional Neural Network*

RNN – ang. *Recurrent Neural Network*

LSTM – ang. *Long Short-Term Memory*

BLE – ang. *Bluetooth Low Energy*

API – ang. *Application Programming Interface*

REST – ang. *Representational State Transfer*

FPS – ang. *Frames per second*

API – ang. *Application Programming Interface*

1. Wstęp

W sporcie nie brakuje rozwiązań wspierających uprawianie go - aplikacje, akcesoria, społeczności, fora - biegacze, rowerzyści czy pływacy mogą korzystać z wielu narzędzi do śledzenia i wspierania swojego rozwoju. Nie jest to jednak prawdziwe dla sportów ekstremalnych i „freestyle’owych”. Na rynku brakuje narzędzi wspierających tych sportowców, pomimo ich rosnącej popularności. Na Igrzyskach Olimpijskich w Tokio w 2020 roku zadebiutowała deskorolka, zyskując tym samym status pełnoprawnego sportu olimpijskiego. Wiąże się to z profesjonalizacją treningów i rosnącym zapotrzebowaniem na narzędzia wspomagające analizę techniczną trików. Dodatkowo, postęp w dziedzinie widzenia komputerowego (ang. *Computer Vision*) daje dziś nowe możliwości tworzenia osobistych, „kieszonkowych” trenerów, które jeszcze kilka lat temu, wymagałyby zaawansowanego sprzętu z laboratorium biomechaniki.

Głównym celem pracy inżynierskiej jest stworzenie platformy mobilnej dla społeczności deskorolkowej, która analizuje nagrania trików deskorolkowych, automatycznie je klasyfikuje oraz ocenia poprawność ich wykonania. Ponadto w aplikacji zaimplementowano interaktywną mapę, którą użytkownicy mogą współtworzyć poprzez dodawanie zdjęć oraz informacji o przeszkodach i stanie obiektów. Zaprojektowane rozwiązanie ma na celu wspieranie rozwoju społeczności, umożliwiając jej członkom śledzenie postępów oraz łatwe lokalizowanie nowych miejsc do jazdy.

W ramach pracy inżynierskiej zrealizowano aplikację mobilną z wykorzystaniem frameworka Flutter (język Dart). W celu realizacji projektu podjęto następujące kroki:

1. Przegląd literatury i rozwiązań istniejących na rynku;
2. Zdefiniowanie założeń oraz architektury systemu, a także dobór technologii;
3. Zaprojektowanie interfejsu użytkownika (ang. *User Interface / User Experience [UI/UX]*);
4. Zebranie i przygotowanie zbioru danych wideo;
5. Wytrenowanie modelu klasyfikacyjnego;
6. Zaimplementowanie modułu mapy;
7. Przeprowadzenie testów funkcjonalnych.

Aplikacja powstała w technologii cross-platformowej, a moduł sztucznej inteligencji działa bezpośrednio na urządzeniu mobilnym (ang. *Edge AI*). Taka decyzja projektowa wynika z fizycznego położenia deskorolkowych „spotów” – często znajdują się one w miejscach zurbanizowanych lub ustronnych, do których nie zawsze dociera stabilny zasięg sieci komórkowej. Dzięki uruchamianiu klasyfikatora lokalnie na telefonie, sportowcy mogą korzystać z pełnej analityki wideo w trakcie jazdy, bez konieczności połączenia z Internetem.

W projekcie świadomie zrezygnowano z implementacji mechanizmów uwierzytelniania, ponieważ specyfika rozwiązania nie wymaga tworzenia profili opartych na architekturze chmurowej. Zamiast tego dane przechowywane są lokalnie na urządzeniu,

a udostępniana mapa działa w trybie globalnym. Takie podejście pozwoliło uniknąć nadmierowej złożoności systemu oraz obniżyło próg wejścia, zapobiegając zniechęceniu potencjalnych użytkowników koniecznością zakładania konta przed pierwszym użyciem aplikacji.

Z analogicznych względów odstąpiono od integracji zewnętrznych czujników sprzętowych (IoT) montowanych bezpośrednio do deskorolki. Jak wykazała przeprowadzona analiza literatury, rozwiązania oparte wyłącznie na wizji komputerowej są znacznie przystępniejsze, a użytkownicy preferują metody bezinwazyjne. Głównym priorytetem stała się maksymalna ergonomia i prostota obsługi, dzięki czemu smartfon pełni rolę jedyne, w pełni samowystarczalne narzędzia analitycznego.

Osobistą motywacją do podjęcia tematu jest zaangażowanie autora pracy w jazdę na deskorolce oraz chęć wsparcia społeczności związanej z tą dyscypliną. Wśród dostępnych narzędzi brakuje rozwiązań wspierających osoby początkujące, dla których obszerne i skomplikowane nazewnictwo trików często stanowi barierę. Ponadto sport ten powszechnie uprawiany jest na ulicznych przeszkodach (tzw. „spotach”), które nie są oficjalnie skatalogowane jako obiekty sportowe. Brak dostępu do informacji o takich miejscach znacząco utrudnia rozwój umiejętności nowym adeptom tego sportu, ograniczając ich wyłącznie do oficjalnych skateparków. Projekt aplikacji wynika bezpośrednio z osobistych doświadczeń autora i trudności napotkanych na początkowym etapie nauki jazdy na deskorolce.

Praca inżynierska została podzielona na siedem głównych rozdziałów. Rozdział pierwszy zawiera wstęp, w którym zdefiniowano problem badawczy, motywację autora, cel oraz zakres pracy. Rozdział drugi zawiera przegląd istniejących na rynku aplikacji sportowych dla społeczności deskorolkowej oraz uzasadnia wybór analizy wizyjnej zamiast czujników sprzętowych. W rozdziale trzecim omówiono założenia projektowe, wybór technologii oraz architekturę systemu. Rozdział czwarty jest poświęcony procesowi projektowania interfejsu użytkownika (UI/UX) aplikacji mobilnej. W rozdziale piątym autor skupił się na szczegółowym opisie opracowania modułu sztucznej inteligencji, w tym przygotowanie zbioru danych oraz wybór i trenowanie sieci neuronowej. Rozdział szósty skupia się na technicznych aspektach implementacji aplikacji w środowisku Flutter, tworzeniu modułu mapy oraz integracji z modelem SI. Pracę zamyka rozdział siódmy, zawierający opis przeprowadzonych testów, ewaluację skuteczności modelu rozpoznającego triki oraz końcowe wnioski.

2. Przegląd istniejących rozwiązań

Poniższy rozdział poświęcono analizie literaturowej oraz przeglądowi rozwiązań dostępnych na rynku. Jego głównym celem jest uzasadnienie kluczowych decyzji projektowych podjętych w pracy, a także zdefiniowanie luki badawczej i rynkowej. W pierwszej kolejności omówiono istniejące aplikacje mobilne dedykowane społeczności deskorolkowej. Następnie przeprowadzono zestawienie metod analizy ruchu w sporcie, porównując zastosowanie czujników sprzętowych z rozwiązaniami opartymi na analizie wideo. W dalszej części przybliżono wybrane modele wizyjnej analizy ruchu. Rozdział zamyka podsumowanie zidentyfikowanych braków w dotychczasowych rozwiązaniach, co stanowi bezpośredni punkt wyjścia dla zaprojektowanego systemu.

2.1. Aplikacje dedykowane dla społeczności deskorolkowej

Na rynku istnieje kilka rozwiązań dedykowanych społeczności deskorolkowej, które oferują różnorodne funkcje wspierające zarówno początkujących, jak i zaawansowanych użytkowników.

SkateSpots

SkateSpots to aplikacja umożliwiająca użytkownikom wyszukiwanie i udostępnianie miejsc do jazdy na deskorolce **wikipedia_skatespots**. Użytkownicy mogą dodawać zdjęcia, opisy oraz informacje o przeszkodach i stanie nawierzchni. Narzędzie to posiada również funkcje społecznościowe, takie jak komentowanie i ocenianie poszczególnych lokalizacji. Oprogramowanie nie dysponuje jednak funkcją rozpoznawania trików deskorolkowych i nie zyskało dużej popularności w Polsce.

FindSkateSpots.com

Znajdująca się pod adresem *findskatespots.com* platforma internetowa stanowi funkcjonalny odpowiednik aplikacji SkateSpots, przeniesiony do środowiska przeglądarkowego **findskatespots**. Serwis charakteryzuje się stosunkowo niewielką bazą aktywnych użytkowników, skoncentrowaną przede wszystkim w Stanach Zjednoczonych. Z punktu widzenia użyteczności, dedykowana aplikacja mobilna stanowi znacznie wygodniejsze i bardziej przystępne źródło informacji dla przeciętnego deskorolkarza.

Skatespot.com

Kolejna platforma internetowa - *skatespot.com* - przeznaczona do lokalizowania skateparków oraz śledzenia aktywności fizycznej **skatespot_home**. Podobnie jak wyżej wymienione rozwiązanie, serwis ten nie został szeroko spopularyzowany wśród docelowej społeczności deskorolkowej.

Skategrounds

Przykładem rozwiązania komercyjnego o zbliżonych założeniach - czyli dążeniu do automatyzacji procesu dokumentowania postępów treningowych przy jednoczesnym mapowaniu infrastruktury sportowej - jest platforma *Skategrounds skategrounds_tech*. System ten opiera się na architekturze hybrydowej, wykorzystującej dedykowany moduł sprzętowy typu IMU (z ang. *Inertial Measurement Unit*) montowany bezpośrednio do podstawy deskorolki. Czujnik ten komunikuje się bezprzewodowo z aplikacją mobilną, przysyłając dane o przyspieszeniu i orientacji przestrzennej deski w czasie rzeczywistym. Urządzenie, oraz miejsce jego umiejscowienia widoczne jest na rysunku 2.1.



Rysunek 2.1. Czujnik *Skategrounds* montowany do podstawy *trucka* deskorolki, Źródło: *skategrounds_tech*.

Mimo innowacyjnego podejścia, system ten wykazuje istotne ograniczenia natury technicznej. Największą wadą tego podejścia jest brak analizy kinematyki ciała użytkownika. Czujnik rejestruje wyłącznie wektory ruchu samej deskorolki, co powoduje, że algorytmy klasyfikujące nie są w stanie odróżnić rotacji samej deskorolki od rotacji deskorolki wraz z tułowiem skatera. Prowadzi to do niskiej precyzji w rozróżnianiu ewolucji o podobnej charakterystyce ruchu sprzętu, ale różnym ułożeniu ciała (np. Frontside 180°, który polega na rotacji zarówno deskorolki, jak i sportowca o 180° przodem do kierunku jazdy, zostanie sklasyfikowany identycznie jak Frontside Shuvit, który polega na rotacji samej deskorolki w tę samą stronę). Ponadto, funkcja mapowania przeszkód sportowych w tej aplikacji ograniczona jest terytorialnie do obszaru Stanów Zjednoczonych, co czyni ją nieużyteczną dla społeczności w innych regionach.

Eksploracja zewnętrznego modułu wiąże się również z istotnymi niedogodnościami użytkowymi, takimi jak konieczność regularnego ładowania ogniwa zasilającego. Ponadto, użytkownik jest zmuszony do stałego dbania o stan techniczny sensora. Ze względu na inwazyjne miejsce montażu — bezpośrednio na konstrukcji deskorolki — urządzenie jest narażone na trudne warunki zewnętrzne. Brak pełnej odporności na wilgoć sprawia, że przypadkowy kontakt z wodą (np. przejazd przez kałużę) może doprowadzić do permanentnego uszkodzenia elektroniki, co w konsekwencji uniemożliwia dalsze korzy-

stanie z systemu. Powyższe czynniki stanowią dodatkową barierę, która często zniechęca sportowców do wyboru rozwiązań opartych na czujnikach sprzętowych.

Spinnax

Kolejnym rozwiązaniem komercyjnym o charakterystyce zbliżonej do platformy *Skategrounds* jest system *Spinnax FREAK*, opracowany przez niemiecki start-up **spinnax_com**. Urządzenie wykorzystuje moduł sprzętowy montowany pod podstawą *trucka* deskorolki, który w odróżnieniu od swojego poprzednika charakteryzuje się pełną wodoodpornością, co minimalizuje ryzyko awarii wynikających z kontaktu z wilgocią. Zasada działania opiera się na integracji dedykowanego sensora o gabarytach przekraczających wymiary modułu *Skategrounds* z aplikacją mobilną za pośrednictwem protokołu bezprzewodowego. System umożliwia rejestrację historii przejazdów w czasie rzeczywistym oraz udostępnia moduł automatycznego nazewnictwa i analizy wykonanych ewolucji. Dodatkową funkcjonalnością jest tryb odtwarzania sekwencji ruchu „krok po kroku”, pozwalający użytkownikowi na manualną weryfikację techniki wykonania triku. Zdjęcie urządzenia wraz ze zrzutem ekranu z aplikacji mobilnej widoczne jest na rysunku 2.2.



Rysunek 2.2. Urządzenie *Spinnax FREAK* oraz dedykowana aplikacja mobilna, Źródło: **spinnax_com**.

Mimo usprawnień w zakresie ochrony fizycznej urządzenia, platforma wykazuje istotne ograniczenia natury technicznej i rynkowej. Podobnie jak w przypadku innych systemów opartych wyłącznie na czujnikach kinematycznych, rozwiązanie to wykazuje niską precyzję w klasyfikacji ewolucji opartych na rotacji ciała użytkownika, co wynika z braku wizyjnej analizy sylwetki skatera. Użyteczność systemu jest dodatkowo ograniczona barierą

językową - interfejs aplikacji dostępny jest wyłącznie w języku niemieckim, co znacząco zawęży potencjalne grono odbiorców. Ponadto platforma nie oferuje funkcji mapowania infrastruktury sportowej, co ogranicza jej rolę w budowaniu społeczności. Krytycznym aspektem z punktu widzenia użytkownika końcowego jest model biznesowy oparty na cyklicznej subskrypcji lub wysokiej opłacie początkowej. Wysoki koszt eksploatacji w stosunku do oferowanych możliwości analitycznych stanowi istotną barierę adopcji tego rozwiązania na rynku masowym.

2.2. Analiza ruchu w sporcie: Wideo a czujniki sprzętowe

Rozpoznawanie ludzkich akcji (z ang. *Human Action Recognition - HAR*) w sporcie polega na wykrywaniu atlety, śledzeniu jego ruchów oraz identyfikacji rodzaju wykonywanej czynności **host2022overview**. Jak wskazują Host i Ivašić-Kos **host2022overview** w swoim przeglądzie, głównym celem systemów HAR jest nie tylko prosta klasyfikacja ruchu, ale również automatyzacja analizy statystycznej oraz monitorowanie wydajności sportowców w celu poprawy ich techniki **host2022overview**.

Wybór analizy wizyjnej zamiast systemów opartych na czujnikach sprzętowych (takich jak moduły IMU) jest uzasadniony kilkoma czynnikami technologicznymi:

- **Bezinwazyjność i dostępność:** Ze względu na wykorzystanie danych wizualnych, stosowanie systemów opartych na wizji komputerowej eliminuje konieczność montowania sensorów na każdym stawie zawodnika, co może być konieczne w przypadku precyzyjnych systemów inercyjnych **host2022overview**.
- **Kompleksowość danych:** Nowoczesne biblioteki, takie jak *TensorFlow* czy *OpenCV* dostarczają szeroką gamę gotowych algorytmów uczenia maszynowego. Pozwala to na automatyczną ekstrakcję cech zamiast ręcznego projektowania deskryptorów, co było domeną starszych metod **host2022overview**.

Mimo tych zalet, implementacja HAR w sporcie wiąże się z wyzwaniami takimi jak okluzja, dynamiczne tło oraz konieczność śledzenia wielu osób jednocześnie, co wymaga zastosowania zaawansowanych modeli klasy uczenia maszynowego **host2022overview**.

Historycznie śledzenie ruchu zawodników opierało się na analizie notacyjnej (ang. *notational analysis*), polegającej na subiektywnej ocenie obserwatora. Był to proces ograniczony do niewielkiej liczby badanych osób i czasochłonny. Współczesna metrologia sportowa dąży do uzyskiwania obiektywnych, ilościowych profili prędkości oraz przyspieszenia co pozwala na głębsze zrozumienie dynamiki koordynacji i strategii taktycznych **barris2008review**.

Pomimo wysokiej precyzji pomiarowej czujników inercyjnych i akcelerometrów, ich praktyczne zastosowanie w warunkach sportowych napotyka na istotne bariery:

- **Bezpieczeństwo i regulacja:** Barris i Button **barris2008review** zauważają, że czujniki noszone przez sportowców są często niedopuszczane do użytku podczas oficjalnych

zawodów i meczów ze względu na restrykcyjne przepisy oraz potencjalne ryzyko kontuzji zawodnika **barris2008review**.

- **Logistyka i motoryka:** Jak wskazują Ahmadi i inni **ahmadi2015toward**, dla rzetelnej oceny ruchu konieczne jest precyzyjne umieszczanie sensorów na każdym stawie będącym przedmiotem zainteresowania. Proces ten nie tylko jest uciążliwy, ale ingeruje również w naturalne wzorce ruchowe sportowca, co jest szczególnie istotne w dyscyplinach wymagających wysokiej zwinności. W przypadku deskorolki, czujniki umieszczane bezpośrednio na niej wpływają na jej wymiary oraz ciężar, co również może mieć wpływ na osiągi atlety **ahmadi2015toward**.
- **Koszty sprzętowe:** W przeciwieństwie do systemów wizyjnych, które mogą wykorzystywać istniejącą infrastrukturę wideo (np. smartfon), systemy oparte na czujnikach wymagają znacznych nakładów na specjalistyczny sprzęt oraz dedykowane zaplecze obliczeniowe **barris2008review**.

Decyzja o wykorzystaniu metod wizyjnych w procesie HAR jest podyktowana potrzebą uzyskania obiektywnych danych, przy jednoczesnym zachowaniu pełnej swobody ruchu sportowca. Ingerowanie w środowisko treningowe zawodników, może mieć negatywny wpływ na ich osiągi. Mimo, że zarówno analiza wizyjna, jak i czujnikowa dążą do tego samego celu, różnią się one znacząco pod względem logistyki wdrożenia oraz wpływu na bezpieczeństwo atlety. Zbiorne zestawienie kluczowych różnic funkcjonalnych i technicznych pomiędzy tymi metodami przedstawiono w tabeli 2.1.

Przejście na zautomatyzowaną analizę wizyjną stwarza jednak własne wyzwania techniczne. Specyfika ruchu w sporcie, charakteryzująca się gwałtownymi zmianami kierunku, wysoką dynamiką oraz, w przypadku sportów zespołowych, kolizjami między zawodnikami, narusza podstawowe założenia o „płynności ruchu”, na których opierają się klasyczne algorytmy śledzące. Według Barris i Button, głównym wyzwaniem pozostaje stabilna identyfikacja i etykietowanie osób w zatłoczonym środowisku, gdzie jakość obrazu, zmiany oświetlenia oraz okluzja utrudniają nieprzerwany monitoring ewolucji **barris2008review**. Pomimo, że deskorolka nie jest sportem zespołowym, w środowisku zawodów bądź na skateparku, wcześniej wspomniane problemy jak najbardziej występują. Z tych powodów współcześnie badania koncentrują się na metodach głębokiego uczenia, które dzięki automatyzacji ekstrakcji cech pozwalają na coraz skuteczniejszą interpretację zachowań w dynamicznych scenach sportowych.

2.3. Modele wizyjnej analizy ruchu

Ewolucja metod wizyjnych w sporcie rozpoczęła się od systemów śledzenia opierających się na detekcji ruchu i statystycznych modelach kształtu. Klasyczne podejścia wykorzystywały tzw. reprezentację typu „blob”, która polega na grupowaniu pikseli o podobnych właściwościach spektralnych w celu wyodrębnienia sylwetki zawodnika z tła **barris2008review**. Jednym z wczesnych systemów tego typu był *Pfinder*, który interpreto-

2. Przegląd istniejących rozwiązań

Tabela 2.1. Porównanie wizyjnej i czujnikowej analizy ruchu w sporcie, Źródło: [opracowanie własne].

Kryterium	Analiza wizyjna (Wideo)	Analiza czujnikowa (IMU)
Inwazyjność	Bezinwazyjna (marker-less), wykorzystuje istniejące dane wizualne barris2008review , host2022overview .	Wymaga fizycznego montażu sensorów na ciele lub sprzęcie barris2008review .
Wpływ na motorykę	Brak ingerencji w naturalne wzorce ruchowe sportowca ahmadi2015toward .	Możliwe zakłócenie ruchu przez czujniki lub okablowanie ahmadi2015toward .
Bezpieczeństwo	Całkowicie bezpieczna dla atlety barris2008review .	Ryzyko kontuzji; czujniki często niedopuszczane do oficjalnych zawodów barris2008review .
Logistyka	Wysoka (np. smartfon); brak konieczności żmudnej kalibracji stawów host2022overview .	Uciążliwa; wymaga precyzyjnego umieszczenia sensorów na każdym stawie ahmadi2015toward .
Koszty	Niskie; wykorzystanie powszechnej infrastruktury wideo barris2008review .	Wysokie nakłady na specjalistyczny sprzęt i zaplecze obliczeniowe barris2008review .
Główne wyzwania	Okluzja, dynamiczne tło, zmiany oświetlenia barris2008review , host2022overview .	Błędy dryfu, konieczność rekalkulacji, bariery regulaminowe barris2008review , ahmadi2015toward .

wał ruch człowieka przy użyciu wieloklasowych modeli statystycznych koloru i kształtu, choć jego skuteczność drastycznie spadała w przypadku wielu zawodników.

Przełomem w dziedzinie HAR stało się zastosowanie głębokiego uczenia, które pozwoliło na pełną automatyzację ekstrakcji cech. Współczesne architektury można sklasyfikować według ich roli w przetwarzaniu danych wideo **host2022overview**:

- **Splotowe sieci neuronowe (CNN):** Wykorzystywane jako klasyfikatory typu *end-to-end*. W analizie sportowej dwuwymiarowe sieci CNN (2D-CNN) służą do ekstrakcji cech przestrzennych z pojedynczych klatek, natomiast trójwymiarowe (3D-CNN) przechwytyją informacje czasowo-przestrzenne, co jest kluczowe dla zrozumienia dynamiki ruchu **host2022overview**.
- **Sieci rekurencyjne (RNN) i LSTM:** Te architektury są projektowane z myślą o przetwarzaniu sekwencji danych, co czyni je idealnymi do analizy wideo klatka po klatce. Sieci LSTM (ang. *Long Short-Term Memory*) wykorzystują specjalne jednostki pamięci do przechowywania stanów czasowych. Pozwala to na klasyfikację złożonych ruchów trwających od kilku do kilkunastu sekund **host2022overview**.
- **Transformery i mechanizmy uwagi:** Najnowszy trend w badaniach nad HAR, pozwalający na lepsze wychwytywanie długoterminowych zależności niż tradycyjne sieci RNN. Zawdzięcza to mechanizmowi samo-uwagi, który uczy się skupiać na

najistotniejszych regionach obrazu (np. kończynach zawodnika) w kontekście całej sceny **host2022overview**.

W analizie dyscyplin technicznych i ekstremalnych, takich jak deskorolka, kluczowe znaczenie ma estymacja pozy. Polega ona na ekstrakcji kluczowych punktów szkieletu, najczęściej stawów. Istnieją na rynku rozwiązania, takie jak *OpenPose*, które pozwalają na uzyskanie precyzyjnych danych o ruchach sportowca bez konieczności stosowania znaczników na jego ciele **openpose2025**. Wybór konkretnego modelu (np. z rodziny *MobileNet* lub *ResNet*) jest zawsze podyktowany kompromisem między dokładnością, a wydajnością obliczeniową, co jest szczególnie istotne w przypadku aplikacji mobilnych działających w czasie rzeczywistym **host2022overview**.

Przykładem nowoczesnego rozwiązania, które bezpośrednio implementuje zasady optymalizacji opisane przez Host i Ivašić-Kos, jest model *Google MoveNet* **movenet2021**. Wykorzystuje on bibliotekę *TensorFlow*, o której autorki wspominają jako o jednym z kluczowych narzędzi umożliwiających szybki rozwój projektów wizyjnych bez konieczności ich budowy od podstaw **host2022overview**. *MoveNet*, opierając się na architekturze CNN, został zaprojektowany z myślą o urządzeniach o ograniczonej mocy obliczeniowej, biorąc pod uwagę rygorystyczny kompromis między dokładnością i szybkością działania. Takie założenia projektowe powodują, że model ten jest zoptymalizowany pod uruchomienie na urządzeniach mobilnych. Dzięki bezmarkerowej ekstrakcji punktów kluczowych, model ten radzi sobie z wyzwaniami okluzji, dynamicznego i nieustrukturyzowanego tła, wspomnianych przez Barris i Button jako jedne z głównych barier tradycyjnych systemów śledzących **barris2008review**. Dodatkowo, *MoveNet* oferuje dwa warianty swojego modelu: *Thunder*, który priorytetyzuje dokładność oraz *Lightning*, w którym większe znaczenie ma szybkość obliczeń. Taki wybór pozwala dostosować model do konkretnego zastosowania **movenet2021**.

2.4. Podsumowanie

Przeprowadzony przegląd istniejących rozwiązań oraz stanu sztuki, wskazuje na postępujący rozwój metod monitorowania sportu - od analizy notacyjnej, w której obserwatorem był człowiek, po zaawansowane systemy automatycznego śledzenia ruchu. W obszarze dyscyplin ekstremalno-technicznych, takich jak deskorolka, wciąż widoczny jest podział na precyzyjne, lecz inwazyjne i kosztowne systemy sprzętowe oraz ogólnodostępne, ale mało zaawansowane platformy społecznościowe.

Kluczowe wnioski z powyższego rozdziału można ująć w następujących punktach:

- **Ograniczenia systemów inercyjnych:** Pomimo wysokiej dokładności, korzystanie z rozwiązań opartych na czujnikach wiąże się z koniecznością montażu dodatkowego sprzętu na deskorolce, co ingeruje w naturalną motorykę sportowca i wyważenie deski. W przypadku rozwiązań takich jak *Skategrounds* użytkownik musi mieć stale

na uwadze obecność czujnika, w przeciwnym wypadku może doprowadzić do permanentnego uszkodzenia kosztownego sprzętu.

- **Bariery ekonomiczne i regulacyjne:** Profesjonalne systemy wizyjne i czujnikowe wymagają wysokich nakładów pieniężnych i sprzętowych, co ogranicza ich dostępność do wąskiej grupy profesjonalistów. Wiele z tych urządzeń nie może być również wykorzystywanych w profesjonalnym środowisku, takim jak zawody sportowe.
- **Potencjał technologii HAR:** Nowoczesne algorytmy HAR oparte na głębokim uczeniu, takie jak architektury CNN, czy modele estymacji pozy (np. *Google MoveNet*), pozwalają na automatyczną ekstrakcję cech bezpośrednio z obrazu wideo. Eliminuje to potrzebę stosowania markerów i czujników, tym samym znacząco ułatwiając zarówno uprawianie sportu, jak i monitorowanie zawodnika.

Podsumowując, na rynku brakuje kompleksowego rozwiązania, które integrowałoby funkcję mapowania infrastruktury sportowej z bezinwazyjną zaawansowaną analizą techniczną trików realizowaną w czasie rzeczywistym na urządzeniu mobilnym. Większość istniejących aplikacji skupia się albo na aspekcie lokalizacyjnym, albo na klasyfikacji ruchu opartej o czujniki sprzętowe, podatne na fizyczne uszkodzenia oraz ingerujące w osiągi sportowca. Niniejszy projekt ma na celu wypełnienie tej luki poprzez implementację platformy do analizy wizyjnej oraz mapowania infrastruktury sportowej, zoptymalizowanej pod urządzenia mobilne. Pozwoli to na obiektywną ocenę postępów treningowych bez nakładów finansowych na dodatkowy sprzęt.

3. Założenia i architektura systemu

Niniejszy rozdział stanowi szczegółowy opis opracowania architektury aplikacji mobilnej integrującej system mapowania infrastruktury sportowej z modułem SI klasyfikującym triki deskorolkowe. Projektowanie systemu poprzedzono porównaniem różnych podejść technologicznych rozważanych przez autora na etapie planowania pracy.

3.1. Wymagania funkcjonalne i нефункционалне

Wymagania projektowe stanowią fundament modelowania systemu, pozwalający na obiektywną ocenę realizacji założonych celów inżynierskich oraz optymalny dobór technologii pod kątem scenariuszy użycia. W literaturze przedmiotu wymagania te dzieli się na funkcjonalne, opisujące konkretne operacje systemu, oraz нефункционалне, definiujące jakość i parametry jego działania.

Wymagania funkcjonalne określają kluczowe operacje, jakie system musi wykonywać w celu wsparcia treningu deskorolkowego:

- Rejestracja oraz odczyt materiałów wideo zawierających ewolucje sportowe;
- Automatyczna klasyfikacja trików z wykorzystaniem algorytmów głębokiego uczenia w celu poprawy techniki zawodnika;
- Udostępnianie interaktywnej mapy obiektów sportowych („spotów”) wraz z funkcją ich edycji i dodawania nowych lokalizacji;
- Prowadzenie lokalnej bazy danych zawierającej historię postępów i wykonanych ewolucji.

Wymagania нефункционалне definiują ograniczenia techniczne i jakościowe, które są niezbędne do zachowania bezinwazyjnego charakteru analizy:

- Realizacja obliczeń modułu klasyfikacji w paradygmacie Edge AI (lokalnie na urządzeniu), co umożliwi pracę w miejscach o ograniczonym zasięgu sieciowym;
- Minimalizacja latencji procesu analizy wizyjnej, zapewniająca niemal natychmiastową informację zwrotną dla sportowca;
- Pełna bezinwazyjność – system nie może wymagać posiadania dodatkowych sensorów ani markerów, co gwarantuje zachowanie naturalnej motoryki ruchu;
- Przezroczystość interfejsu użytkownika oraz wysoki poziom użyteczności modułu mapy.

Precyzyjne zdefiniowanie powyższych priorytetów determinuje wybór architektury oraz stosu technologicznego wykorzystanego w dalszej części pracy.


3.2. Wybór technologii

Proces wyboru technologii opierał się na weryfikacji dwóch skrajnych koncepcji architektury sprzętowo programowej. Wstępne założenia projektowe zakładały wykorzystanie zewnętrznych czujników inercyjnych montowanych bezpośrednio na deskorolce. Na dal-

szym etapie rozwoju projektu zdecydowano się na podejście analizy wizyjnej, z powodów szerzej rozwiniętych w drugim rozdziale pracy inżynierskiej.

3.2.1. Podejście IoT (czujnikowe)


W pierwszej fazie rozważano system typu IoT, w którym mikrokontroler (np. ESP32) agregowałby dane z akcelerometru i żyroskopu, przysyłając je do dedykowanego *backendu* opartego na frameworku *FastAPI* za pośrednictwem protokołu *Bluetooth Low Energy* (BLE). Schemat takiego rozwiązania przedstawiono na rysunku 3.1.



Rysunek 3.1. Schemat czujnikowej architektury systemu, Źródło: [Opracowanie własne].

Koncepcja ta została rozwinięta w stronę rozwiązania hybrydowego, w którym dane czujnikowe miały służyć jako multimodalny zbiór danych wspierający proces trenowania klasyfikatora. W tym scenariuszu użytkownik końcowy korzystałby wyłącznie z analizy wizyjnej, co eliminowałoby potrzebę montażu dodatkowych urządzeń na sprzęcie sportowym. Zmodyfikowany schemat architektury systemu widoczny jest na rysunku 3.2.

Biorąc jednak pod uwagę bariery logistyczne oraz ryzyko uszkodzenia elektroniki eksploatowanej w trudnych warunkach zewnętrznych, obie koncepcje uznano za nieefektywne. Jak wykazała analiza literatury, sensory montowane bezpośrednio na deskorolce nie pozwalają na analizę ruchu poszczególnych stawów sportowca, co drastycznie obniża precyzję klasyfikacji ewolucji opartych na złożonej rotacji ciała. Wykorzystanie danych czujnikowych jedynie w fazie treningowej również wiązało się z istotnymi wyzwaniami merytorycznymi. Brak obiektywnych wzorców odniesienia wymuszałby oparcie procesu



Rysunek 3.2. Schemat hybrydowej architektury systemu, Źródło: [Opracowanie własne].

etykietowania danych na analizie notacyjnej, czyli subiektywnej ocenie obserwatora. Taka metodologia jest nie tylko czasochłonna, ale również obciążona błędem ludzkim, co w kontekście budowy rzetelnego systemu automatycznego rozpoznawania akcji (HAR) czyni ją niemiarodajną pod względem naukowym i technicznym.


3.2.2. Podejście wizyjne (*Edge AI*)

W opozycji do systemów inercyjnych, ostateczna koncepcja systemu została oparta na paradygmacie analizy wizyjnej realizowanej w całości na urządzeniu mobilnym (ang. *on-device processing*). Wybór ten podyktowany był dążeniem do pełnej bezinwazyjności pomiarowej, wskazywanej jako kluczowy warunek zachowania naturalnej motoryki ruchu sportowca. Architektura ta, przedstawiona na rysunku 3.3, stanowi implementację systemu HAR, który eliminuje błędy wynikające z braku analizy ułożenia ciała użytkownika.

Warstwa prezentacji oraz logika biznesowa aplikacji zostały zaimplementowane w frameworku *Flutter*, co zapewnia wysoką wydajność interfejsu przy zachowaniu wielopłatformowości kodu źródłowego. Moduł mapy, kluczowy dla funkcji lokalizowania obiektów sportowych, oparto na bibliotece *flutter_map*. Wykorzystuje ona dane z otwartego projektu *OpenStreetMap*, co pozwala na elastyczne zarządzanie warstwami wizualnymi i keshowanie kafelków mapy, zwiększając użyteczność systemu w warunkach ograniczonej łączności sieciowej.

Najistotniejszym elementem technologicznym jest silnik analityczny wykorzystujący

bibliotekę *TensorFlow Lite* – zoptymalizowane środowisko uruchomieniowe dla modeli uczenia maszynowego na systemy wbudowane i mobilne. Za proces ekstrakcji cech przestrzennych odpowiada model *Google MoveNet* w wariantcie *Thunder*. Został on wybrany ze względu na rygorystyczny kompromis pomiędzy wysoką precyzją lokalizacji punktów kluczowych (stawów), a ograniczonymi zasobami sprzętowymi smartfonów. Tak skonstruowany potok przetwarzania danych (ang. *data pipeline*) pozwala na bezmarkerowe śledzenie sylwetki w czasie rzeczywistym, co stanowi fundament dla warstwy klasyfikacyjnej trików deskorolkowych.



Rysunek 3.3. Schemat wizyjnej architektury systemu, Źródło: [Opracowanie własne].

3.3. Architektura systemu

Docelowa struktura aplikacji, widoczna na rysunku 3.3, opiera się na realizacji możliwie jak największej ilości procesów logicznych bezpośrednio na urządzeniu mobilnym. Takie zdecentralizowane podejście gwarantuje najwyższy poziom prywatności danych oraz niezawodność systemu w miejscach o ograniczonym zasięgu sieci komórkowej. Struktura aplikacji została podzielona na kilka współpracujących ze sobą modułów.

Głównym elementem interfejsu jest *frontend*, opracowany w technologii *Flutter*, który odpowiada za nagrywanie i odczyt materiałów wideo, prezentację historii wykonanych ewolucji oraz umożliwienie użytkownikowi korzystanie z mapy skateparków i przeszkód. Dane wejściowe dostarczane są przez moduł aparatu, który umożliwia rejestrację obrazu przy użyciu biblioteki *camera* lub wybór istniejących nagrań za pomocą komponentu *image picker*. Nagranie trafia następnie do modułu SI, gdzie model *MoveNet* dokonuje ekstrakcji pozy. Skonwertowany materiał jest klasyfikowany i oceniany z wykorzystaniem

TensorFlow Lite. Realizacja tych procesów bezpośrednio na urządzeniu pozwala na szybką identyfikację triku bez konieczności przesyłania dużych plików do zewnętrznego serwera.

Za aspekt społecznościowy i współdzielenie danych odpowiada moduł mapy, integrujący bibliotekę *flutter_map* z danymi *OpenStreetMap*. Komunikuje się on z backendem zaimplementowanym w języku *Python*, z wykorzystaniem frameworku *FastAPI*. Warstwa serwerowa zarządza globalną listą miejsc do jazdy, zapewnia szyfrowanie danych oraz udostępnia zasoby przez protokół *REST API* (z ang. *Representational State Transfer Application Programming Interface*). Zgodnie z założeniami projektowymi, system zapewnia dostęp do danych bez konieczności tworzenia kont użytkowników i autoryzacji, tym samym znacząco obniżając próg wejścia dla społeczności. Warstwę trwałości danych stanowi baza danych, wykorzystująca serwer *PostgreSQL* do zarządzania zasobami globalnymi (listą „spotów” deskorolkowych) oraz lokalną bazę *SQLite* do przechowywania historii trików bezpośrednio na urządzeniu.

4. Projekt interfejsu użytkownika

Niniejszy rozdział opisuje proces projektowania warstwy prezentacji aplikacji mobilnej, ze szczególnym uwzględnieniem zasad użyteczności oraz specyfiki środowiska, w jakim system będzie eksploatowany. Głównym celem projektowym na tym etapie prac było stworzenie intuicyjnego interfejsu, który umożliwi sportowcom intuicyjne znajdowanie miejsc do jazdy oraz szybki dostęp do funkcji analitycznych, bez konieczności przerywania sesji treningowej.

Istotnym założeniem tego etapu było rozdzielenie fazy koncepcyjnej i prototypowania od samej implementacji kodu źródłowego aplikacji. Umożliwiło to skupienie się na ergonomii i logice *UI/UX* przed przystąpieniem do prac programistycznych, opisanych szczegółowo w rozdziale szóstym.

4.1. Założenia projektowe i makiety aplikacji

Proces projektowania interfejsu oparto na paradygmacie projektowania zorientowanego na użytkownika. Głównym narzędziem wykorzystywanym do stworzenia makiet aplikacji było środowisko *Figma*. Za jego pomocą wypracowano wstępny układ elementów graficznych oraz prototyp interakcji z użytkownikiem przed ich wdrożeniem w środowisku *Flutter*.

Należy podkreślić, że makiety powstałe na tym etapie pracy inżynierskiej stanowią idealizację systemu. Służyły one przede wszystkim jako punkt odniesienia podczas projektowania rzeczywistego interfejsu. Finalny produkt różni się w pewnym stopniu od prototypów zaprezentowanych w tym rozdziale, co wynika z technicznych ograniczeń bibliotek mobilnych oraz optymalizacji interfejsu pod kątem wydajności na urządzeniach o mniejszej mocy obliczeniowej. W tej części pracy przedstawiono wizję projektową i założenia estetyczne, a rzeczywisty wygląd oraz techniczne detale wdrożonych komponentów zostały przedstawione w rozdziale poświęconym implementacji aplikacji.

Jako komercyjną nazwę aplikacji wybrano angielskie słowo *Flatground*, pisane wielkimi literami. Oznacza ono w dosłownym tłumaczeniu płaską ziemię, natomiast w slangu deskorolkowym, słowo to figuruje jako określenie płaskiego miejsca do jazdy, bez przeszkód, na którym można wykonywać triki. Z racji tego, że projekt skupia się na klasyfikacji trików wykonywanych właśnie na „flacie” (czyli skrótowym, spolszczonym odpowiedniku angielskiego *flatground*), nazwa ta będzie wywoływała adekwatne skojarzenia i będzie dobrze rezonować ze społecznością deskorolkową.


4.2. Nawigacja i główne ekrany aplikacji

Projekt interfejsu aplikacji *FLATGROUND* został podporządkowany nadrzędnemu celowi, jakim jest prostota oraz intuicyjność systemu. Zrezygnowano ze skomplikowanych struktur zagnieżdżonych menu na rzecz płaskiej architektury informacji, co pozwala

użytkownikowi na natychmiastowe przełączanie się między modulem aplikacji, a mapy. Główną osią nawigacyjną systemu jest górny pasek zakładek, który dzieli aplikację na dwa kluczowe moduły. W celu trafienia do szerszej grupy odbiorców, ekran aplikacji został zaprojektowany w języku angielskim.

4.2.1. Ekran mapy (*Spot Map*)

Ekran mapy, widoczny na rysunku 4.1, stanowi centrum funkcji społecznościowych aplikacji. Interfejs został zaprojektowany tak, aby maksymalnie wykorzystać przestrzeń ekranu na interaktywny widok mapy, na którym naniesiono markery reprezentujące obiekty sportowe.




Rysunek 4.1. Makieta ekranu mapy aplikacji, Źródło: [Opracowanie własne].

Zakładka podzielona jest na 2 części: interaktywną mapę, zajmującą większość ekranu oraz listę „spotów” deskorolkowych zlokalizowanych niedaleko od użytkownika. Na mapie widoczne są markery z lokalizacjami przeszkód i lokalizacja użytkownika. Z kolei lista, pozwala na podgląd informacji na temat obiektów sportowych - nazwę, typ oraz adres.

4.2.2. Ekran wykrywania trików (*Detect Trick*)

Ekran dedykowany wykrywaniu trików, widoczny na rysunku 4.2, implementuje minimalistyczny i wysokokontrastowy design.




Rysunek 4.2. Makieta ekranu detekcji triku aplikacji, Źródło: [Opracowanie własne].

Ekran aplikacji podzielony został na 3 części:

- **Obsługa materiału wideo** - ta sekcja zawiera ramkę podglądu z dwoma wyraźnie widocznymi przyciskami: *RECORD* (z ang. „nagraj”) i *UPLOAD* (z ang. „importuj”). Taki układ dużych, czytelnych elementów minimalizuje ryzyko pomyłki i ułatwia obsługę smartfona jedną ręką;
- **Wyniki klasyfikacji** - sekcja pojawia się bezpośrednio pod modułem nagrywania. Kluczowa informacja, czyli rozpoznany trik (z ang. *Performed Trick*, w tym przypadku *Ollie*), jest zaprezentowana dużą czcionką, w centralnym miejscu ekranu, wraz z procentowym wskaźnikiem pewności klasyfikacji (z ang. *Accuracy*). Na tym etapie projektowania przewidywano szczegółową analitykę w postaci statystyk technicznych: *Pop* - siła wybicia, *Board rotation* - rotacja deskorolki oraz *Confidence* - pewność

wykonywanego triku. Jednak ze względu na brak obiektywnych wzorców, na których można byłoby oprzeć takie statystyki, w późniejszych stadiach zrezygnowano z tych metryk;

- **Historia trików** - widoczna na rysunku 4.3 sekcja prezentuje użytkownikowi pięć ostatnich przeanalizowanych trików wraz z metryką *Confidence*. Pozwala ona na szybkie przypomnienie ewolucji ćwiczonych w danej sesji treningowej oraz jej ustrukturyzowanie.



Rysunek 4.3. Makieta ekranu historii trików aplikacji, Źródło: [Opracowanie własne].

Podział aplikacji na powyższe sekcje został podyktowany motywacją do stworzenia intuicyjnego i przejrzystego narzędzia treningowego. Zastosowana kolorystyka, oparta na odcieniach bieli i fioleto, zapewnia wysoki kontrast, co było jednym z wymagań niefunkcjonalnych dotyczących czytelności interfejsu w warunkach oświetlenia zewnętrznego. Całość dąży do bycia „przezroczystym” narzędziem, które nie odciąga uwagi od treningu, a jedynie dostarcza niezbędnych danych w optymalnej formie.

4.3. Interakcja użytkownika z modulem rozpoznawania trików

W fazie projektowania w programie *Figma* szczególną uwagę poświęcono interakcji użytkownika z narzędziem do analizy wizyjnej. Zaprojektowano sekwencyjny proces, który prowadzi użytkownika od momentu uruchomienia kamery, przez wybór pliku za pomocą komponentu *image picker*, aż do prezentacji wyniku analizy.

Interakcja z modulem SI została zaprojektowana w sposób asynchroniczny, co w praktyce inżynierskiej oznacza oddelegowanie zasobochłonnych obliczeń do zadań wykonywanych w tle, poza głównym wątkiem interfejsu użytkownika. Dzięki takiemu podejściu aplikacja zachowuje pełną responsywność - użytkownik nie doświadcza „zamrożenia” ekranu podczas analizy wizyjnej. W trakcie oczekiwania na wynik, w głównym oknie aplikacji wyświetlany jest podgląd zarejestrowanego materiału wideo, co pozwala na natychmiastową weryfikację nagrania przez sportowca.

Finalny sposób prezentacji danych skupia się na dostarczeniu czytelnego sprzężenia zwrotnego w formie dashboardu analitycznego. Zamiast surowej reprezentacji szkieletowej, która mogłaby być nieczytelna dla użytkownika, system wyświetla nazwę rozpoznanego triku oraz szczegółowe metryki techniczne. Taka forma prezentacji ma na celu dostarczenie użytkownikowi obiektywnych danych o wykonanej ewolucji, co bezpośrednio realizuje założenie o stworzeniu bezinwazyjnego, mobilnego narzędzia wspomagającego trening. Wizualizacja ta została zoptymalizowana pod kątem użyteczności, zastępując skomplikowane wykresy prostymi wskaźnikami liczbowymi, co ułatwia szybką analizę błędów bezpośrednio po wykonaniu triku.

5. Opracowanie modułu sztucznej inteligencji

Niniejszy rozdział poświęcono szczegółowemu omówieniu procesu projektowania oraz implementacji modułu sztucznej inteligencji. Stanowi on główny silnik analityczny zaprojektowanej aplikacji mobilnej. Zgodnie z założeniami projektowymi opisanymi w rozdziale trzecim, klasyfikacja trików realizowana jest w oparciu o analizę wizyną działającą bezpośrednio na urządzeniu końcowym (w tym przypadku smartfonie użytkownika). Ze względu na złożoność tego zagadnienia, proces tworzenia systemu rozpoznawania ruchu podzielono na kilka kluczowych etapów, opisanych w kolejnych podrozdziałach.

5.1. Zbiór danych treningowych

Do wytrenowania modelu klasyfikacyjnego wykorzystano ogólnodostępny zbiór danych wideo o nazwie „*Skateboarding Trick Dataset (120fps)*”, udostępniony na platformie badawczej Kaggle **kaggle_skateboarding_dataset**. Wybrany zbiór zawiera nagrania wideo przedstawiające osiem różnych klas ewolucji deskorolkowych:

- Ollie,
- Kickflip,
- Heelflip,
- Frontside Shuvit,
- Shuvit,
- Backside 180,
- Frontside 180,
- Pressure Flip.

W zbiorze znajduje się po około pięćdziesiąt nagrań do każdej z klas.

Początkowe plany projektowe zakładały rozbudowę bazy treningowe poprzez połączenie jej z zewnętrznymi materiałami, takimi jak repozytorium *SkateboardML*, udostępnione w serwisie *GitHub* przez użytkownika *LightningDrop lightningdrop2024*. Po dokładnej analizie danych źródłowych zdecydowano się jednak na odrzucenie tej koncepcji z uwagi na wysokie ryzyko błędów architektonicznych. Zewnętrzny zbiór zawierał po około 100 próbek wideo i ograniczał się tylko do dwóch klas (Ollie oraz Kickflip). Integracja tak ograniczonych danych ze zbalansowanym zbiorem z platformy *Kaggle* mogłaby doprowadzić do drastycznego zaburzenia równowagi klas. Z punktu widzenia uczenia maszynowego skutkowałoby to wykształceniem przez sieć neuronową tzw. obciążenia (z ang. *bias*) - model zacząłby sztucznie faworyzować te ewolucje, których próbek byłoby znacząco więcej niż innych (w tym przypadku Ollie i Kickflip). Przełożyłoby się to na znaczący wzrost liczby fałszywych detekcji podczas użytkowania aplikacji.

Istotnym wyzwaniem inżynierskim była również rozbieżność w parametrach nagrań. Filmy z platformy *Kaggle* były nagrywane z częstotliwością 120 klatek na sekundę (FPS - z ang. *Frames per second*), podczas gdy aparaty docelowych urządzeń mobilnych pracują

zazwyczaj w standardzie 30 FPS. Aby zapobiec wyuczeniu przez model nienaturalnie wolnej dynamiki ruchu, zastosowano w kodzie mechanizm odrzucania klatek, powodując tym samym konwersję wideo do 30 FPS.

Należy zauważyć, że choć wielkość zastosowanego zbioru danych jest stosunkowo skromna jak na standardy komercyjnych systemów sztucznej inteligencji, jest to ilość w zupełności wystarczająca do opracowania funkcjonalnego prototypu (z ang. *Proof of Concept*) i poprawnej walidacji koncepcji w ramach pracy inżynierskiej. Ewentualne powiększenie zbioru danych mogłoby w przyszłości zostać zrealizowane poprzez proces tzw. *crowdsourcingu*, wykorzystując nagrania nadsyłane anonimowo przez aktywnych użytkowników aplikacji.

5.2. Ekstrakcja cech i estymacja pozy

Ze względu na wysoką złożoność obliczeniową surowych plików wideo, zdecydowano się na podejście oparte na detekcji cech przestrzennych szkieletu ludzkiego. Wykorzystano w tym celu model estymacji pozy *Google MoveNet* pobrany z repozytorium *TensorFlow Hub* **openpose2025**. Model ten posiada dwa warianty:

- **Thunder**, w którym priorytetyzowana jest precyzja działania;
- **Lightning**, w przypadku którego kluczowa jest szybkość działania.

W przypadku niniejszej pracy inżynierskiej zdecydowano się na skorzystanie z wersji *Thunder*, ponieważ w przypadku analizy tak dynamicznego i skomplikowanego ruchu, jakim jest jazda na deskorolce, wysoka precyzja jest kluczowa.

Proces ekstrakcji pozy przebiegał w sposób ujednolicony dla każdej klatki. Najpierw obraz był skalowany i uzupełniany czarnymi pasami do wymiarów wejściowych wymaganych przez model, tj. 256x256 pikseli. Następnie *MoveNet* przeprowadzał inferencję, lokalizując 17 kluczowych punktów szkieletu, takich jak stawy skokowe, kolanowe, ramiona czy biodra. Dla każdego punktu model zwraca trzy wartości: współrzędną X, współrzędną Y oraz współczynnik pewności wykrycia. W wyniku tej operacji każda klatka obrazu redukowana była do wektora jednowymiarowego składającego się z 51 cech numerycznych, co drastycznie obniżyło objętość danych przesyłanych do głównego klasyfikatora.

5.3. Preprocessing i normalizacja danych

Po ekstrakcji punkty kluczowe wymagały przekształcenia do postaci zrozumiałej dla modelu analizującego szeregi czasowe. Zebrane dane zostały uporządkowane chronologicznie, a etykiety tekstowe (nazwy trików) poddano kodowaniu numerycznemu za pomocą narzędzia *LabelEncoder*.

W celu uchwycenia dynamiki ruchu, zastosowana została technika przesuwnego okna (z ang. *sliding window*). Rozmiar okna wejściowego ustawiono na 30 klatek, co przy znormalizowanej prędkości 30 FPS odpowiada dokładnie jednej sekundzie nagrania, co jest optymalnym czasem na wykonanie triku deskorolkowego. W celu powiększenia liczby

unikalnych próbek, zastosowano przesunięcie okna o 2 klatki. Ostateczny zbiór danych składał się z trójwymiarowych tensorów o kształcie (30, 51) (30 klatek wideo, 51 cech w każdej klatce - iloczyn 17 punktów na ciele i 3 informacji dla każdego punktu), który następnie podzielono na zbiór treningowy i walidacyjny w klasycznej proporcji 80:20, gwarantując obiektywną ewaluację modelu.

5.4. Architektura modelu klasyfikacyjnego

Na etapie doboru algorytmu decyzyjnego odrzucono ciężkie sieci rekurencyjne (np. *LSTM*) na rzecz szybkiej, jednowymiarowej sieci neuronowej *1D-CNN*. Sieci te zostały opisane szerzej w podrozdziale 2.3, warto jednak zaznaczyć, iż wybrana architektura charakteryzuje się znacznie mniejszym zapotrzebowaniem na moc obliczeniową oraz zoptymalizowanym procesem wnioskowania, co bezpośrednio wpisuje się w założenia platformy docelowej, umożliwiając płynne działanie klasyfikatora lokalnie, wykorzystując wyłącznie moc obliczeniową procesora smartfona.

Zaprojektowana sieć neuronowa składa się z następujących elementów operacyjnych:

- **Warstwa wejściowa:** przyjmująca sekwencje tensorów czasowo przestrzennych.
- **Pierwszy blok spłotowy:** jednowymiarowa warstwa spłotowa, wyodrębniająca lokalne wzorce ruchu przy użyciu 64 filtrów oraz nieliniowej funkcji aktywacji ReLU. Bezpośrednio za nią zastosowano warstwę odrzucania, dezaktywującą 30% neuronów w celu zapobiegania zjawisku przeuczenia, oraz warstwę łączenia maksymalnego, odpowiedzialną za redukcję wymiarowości czasowej i wygładzenie rejestrowanego sygnału.
- **Drugi blok spłotowy:** kolejna jednowymiarowa warstwa spłotowa, poszerzona do 128 filtrów, zintegrowana z analogicznymi mechanizmami regularyzacji i zrzeszania przestrzennego.
- **Blok w pełni połączony:** warstwa spłaszczająca (z ang. *Flatten*), dokonująca transformacji wyuczonych wielowymiarowych map cech do postaci wektora jednowymiarowego. Tak przetworzone dane przekazywane są do gęstej warstwy ukrytej, zbudowanej z 64 neuronów z funkcją aktywacji ReLU.
- **Warstwa wyjściowa:** warstwa gęsta wyposażona w 8 neuronów, których liczba odpowiada ilości rozpoznawanych klas ewolucji. Operuje ona na funkcji aktywacji *Softmax*, która poddaje sygnały wyjściowe normalizacji, tworząc ostateczny rozkład prawdopodobieństwa przynależności analizowanej sekwencji do każdej z dyskretnych klas.

5.5. Trenowanie modelu i konwersja TensorFlow Lite

Proces optymalizacji wag w zaprojektowanej sieci spłotowej zrealizowano przy użyciu adaptacyjnego algorytmu optymalizacji *Adam* (z ang. *Adaptive Movement Estimation*). Algorytm ten dynamicznie dostosowuje czynniki uczenia dla poszczególnych wag na

podstawie estymacji pierwszego i drugiego momentu gradientu, co pozwala na szybszą i bardziej stabilną zbieżność modelu. Celem optymalizacji była minimalizacja funkcji straty opartej na rzadkiej entropii krzyżowej (z ang. *Sparse Categorical Crossentropy*). Proces uczenia zaplanowano na maksymalnie 50 epok, w trakcie których dane treningowe przetwarzano w mniejszych pakietach liczących po 32 próbki.

W celu maksymalizacji zdolności modelu do generalizacji (poprawnego rozpoznawania nowych, nieznanych wcześniej nagrań) oraz zapobiegania zjawisku przeuczenia, zastosowano technikę regularyzacji zwaną wczesnym zatrzymywaniem. Polega ona na ciągłym monitorowaniu wartości funkcji straty na niezależnym zbiorze walidacyjnym po każdej epoce. Algorytm został zaprogramowany tak, aby automatycznie przerwać proces uczenia, jeżeli błąd walidacyjny nie uległ zmniejszeniu przez 10 kolejnych iteracji. Po takim zatrzymaniu, przywracane i zapisywane były te wagi sieci, dla których odnotowano najniższą wartość błędu, gwarantując wybór najbardziej optymalnego stanu modelu.

Finalnym etapem prac nad silnikiem analitycznym była konwersja skomplikowanej sieci do lekkiego formatu binarnego, zoptymalizowanego pod kątem urządzeń o ograniczonych zasobach sprzętowych. W trakcie konwersji zastosowano rygorystyczne reguły kompilacji. Wymuszono mapowanie warstw sieci neuronowej wyłącznie na zbiór podstawowych operacji matematycznych, które są natywnie i sprzętowo wspierane przez procesory smartfonów. Tym samym zrezygnowano z implementacji złożonych, zewnętrznych instrukcji obliczeniowych macierzystej biblioteki programistycznej. Takie ograniczenie przestrzeni operacyjnej pozwoliło na znaczną redukcję objętości pliku wynikowego w formacie *.tflite* oraz zagwarantowało wydajne, bezproblemowe wnioskowania modelu na mobilnych architekturach procesorów.

6. Budowa aplikacji mobilnej i warstwy serwerowej

Niniejszy rozdział poświęcono szczegółowemu opisowi architektury oraz implementacji warstwy użytkownika systemu w postaci aplikacji mobilnej. Aplikacja ma na celu integrację funkcji mapowania skateparków z modułem analizy wizyjnej, realizującym wnioskowanie w czasie rzeczywistym na urządzeniu końcowym. W dalszej części rozdziału przedstawiono organizację kodu źródłowego, integrację interaktywnego modułu mapy, sposób działania modułu analizującego i klasyfikującego nagrania trików deskorolkowych oraz architekturę integracji uczenia maszynowego.

6.1. Struktura projektu w środowisku Flutter

Aplikacja mobilna została zrealizowana z wykorzystaniem wieloplatformowego framework'a *Flutter* oraz języka programowania *Dart*. Wybór tej technologii ukierunkowany był przede wszystkim uniwersalnością (*Flutter* działa zarówno na telefonach z systemem *Android*, jak i *iOS*). Ponadto posiada on możliwość kompilacji kodu źródłowego bezpośrednio do natywnych instrukcji procesorów o architekturze ARM, co zapewnia wysoką wydajność renderowania interfejsu użytkownika.

Architektura oprogramowania została zaprojektowana w oparciu o wzorzec podziału odpowiedzialności (z ang. *Separation of concerns*), wyodrębniający trzy główne warstwy:

1. **Warstwę prezentacji** (*UI*) odpowiedzialną za renderowanie komponentów interfejsu, zarządzanie stanem widoków oraz obsługę zdarzeń dotykowych użytkownika.
2. **Warstwę logiki biznesowej i dziedzicznej** zawierającą struktury danych oraz algorytmy przetwarzania danych wejściowych.
3. **Warstwę usług** realizującą komunikację sieciową z interfejsem *API* (z ang. *Application Programming Interface* - Interfejs programowania aplikacji) oraz niskopoziomowe operacje na urządzeniu końcowym (kamera, akceleratory uczenia maszynowego).

W głównej funkcji programu (`main ()`) zaimplementowano wstępną konfigurację aplikacji. Za pomocą klasy *SystemChrome* włączono tryb pełnoekranowy, ukrywając systemowe paski nawigacyjne. Pozwoliło to maksymalnie wykorzystać przestrzeń ekranu na potrzeby podglądu kamery oraz interaktywnej mapy. Spójność wizualną interfejsu zapewniono poprzez zdefiniowanie motywu głównego opartego na kroju pisma *Poppins*.

6.2. Integracja modułu mapy

Moduł mapy odpowiada za wizualizację, rejestrację oraz edycję punktów reprezentujących skateparki, obiekty sportowe i „spoty” deskorolkowe. Warstwa komunikacji sieciowej została wyizolowana w ramach klasy *SkateSpotApi* operującej na protokole HTTP z wykorzystaniem architektury *RESTful*.

W celu ułatwienia testowania i wdrażania aplikacji, zaimplementowano funkcję dynamicznego wyboru adresu bazowego serwera (`_resolveBaseUrl`). Metoda ta sprawdza

zmienne środowiskowe przekazane podczas kompilacji i automatycznie dobiera odpowiedni adres URL:

- dla środowiska lokalnego (deweloperskiego) kieruje zapytania pod adres IP emulatora Androida - `http://10.0.2.2:8000`,
- dla środowiska produkcyjnego wykorzystuje adres serwera w chmurze (*Render*),

Widoczna na poniższym załączniku metoda `_resolveBaseUrl` odpowiada za dynamiczny dobór adresu bazowego API.

```
1 static String _resolveBaseUrl({String? override}) {
2   if (override != null && override.isNotEmpty) {
3     return override.replaceAll(RegExp(r'/$'), '');
4   }
5   const explicit = String.fromEnvironment('BACKEND_BASE_URL', defaultValue: '');
6   if (explicit.isNotEmpty) {
7     return explicit.replaceAll(RegExp(r'/$'), '');
8   }
9   const appEnv = String.fromEnvironment('APP_ENV', defaultValue: 'dev');
10  if (appEnv == 'prod') {
11    const prodUrl = String.fromEnvironment(
12      'PROD_BACKEND_BASE_URL',
13      defaultValue: 'https://flatground.onrender.com',
14    );
15    return prodUrl.replaceAll(RegExp(r'/$'), '');
16  }
17  return 'http://10.0.2.2:8000';
18 }
```

Listing 1. Metoda `_resolveBaseUrl`.

Dane przesłane z serwera w formacie JSON są przekształcane na obiekty reprezentujące skateparki za pomocą klasy `SkateSpot`. API obsługuje pełen zestaw operacji CRUD (z ang. *Create, Read, Update, Delete*), umożliwiając m. in. pobieranie listy obiektów wraz ze współrzędnymi geograficznymi, dodawanie szczegółowych opisów, określanie poziomu trudności oraz dołączanie zdjęć. Aby zapobiec awarii aplikacji w przypadku braku połączenia z internetem, zapytania sieciowe zabezpieczono obsługą błędów opartą na klasie `HttpException`.

6.3. Obsługa kamery i zarządzanie plikami wideo

Automatyczne rozpoznawanie trików wymaga pobrania i wstępnej obróbki nagrania z kamery smartfona. Z powodu dużej różnorodności modeli telefonów, powodującej dużą rozbieżność rozdzielczości i proporcji obrazu, materiał wideo przed przekazaniem do modeli uczenia maszynowego musi zostać ustandaryzowany.

Na proces przygotowania danych wideo składają się dwa główne etapy:

- **Normalizacja przestrzenna klatek:** Każda klatka filmu ulega przeskalowaniu z zachowaniem oryginalnych proporcji obrazu, a następnie umieszczana w kwadratowej macierzy o wymiarach 256×256 pikseli. Ewentualny wolny obszar powstały na skutek tej konwersji, uzupełniany jest czarnymi pasami, co zapobiega rozciąganiu czy spłaszczaniu sylwetki skatera. Takie zniekształcenie nagrania mogłoby zaburzyć dokładność detekcji punktów kluczowych przez model *MoveNet*.
- **Normalizacja czasowa sekwencji:** Długości nagrań wgrywanych przez użytkowników różnią się od siebie, a główny klasyfikator wymaga wejścia o stałym wymiarze 30 klatek. Aby to osiągnąć, zaimplementowano funkcję `_resampleKeypointSequence`, która przekształca sekwencję punktów kluczowych o dowolnej długości do wymaganego rozmiaru 30 klatek za pomocą liniowej interpolacji współrzędnych.

Na poniższym załączniku widoczny jest algorytm liniowej interpolacji i resamplingu sekwencji punktów kluczowych `_resampleKeypointSequence`.

```

1 List<List<double>> _resampleKeypointSequence(List<List<double>> source,
2 int targetLength) {
3     if (source.isEmpty) {
4         return List.generate(targetLength, (_) => List.filled(51, 0.0));
5     }
6     if (source.length == targetLength) return source;
7     if (source.length == 1) {
8         return List.generate(targetLength, (_) => List<double>.from(source.first));
9     }
10    final List<List<double>> out = [];
11    final double step = (source.length - 1) / (targetLength - 1);
12    for (int i = 0; i < targetLength; i++) {
13        final pos = i * step;
14        final left = pos.floor();
15        final right = pos.ceil().clamp(0, source.length - 1);
16        if (left == right) {
17            out.add(List<double>.from(source[left]));
18            continue;
19        }
20        final t = pos - left;
21        final leftFrame = source[left];
22        final rightFrame = source[right];
23        final blended = List<double>.generate(
24            51,
25            (j) => leftFrame[j] * (1.0 - t) + rightFrame[j] * t,
26        );
27        out.add(blended);
28    }
29    return out;
30 }

```

Listing 2. Algorytm `_resampleKeypointSequence`

Pliki wideo nie są przechowywane w pamięci urządzenia ze względu na brak użytecznego uzasadnienia takiego rozwiązania oraz potencjalne zużywanie zasobów pamięci urządzenia w przypadku nagromadzenia znacznej ilości nagrań. Zamiast tego, użytkownik ma dostęp do historii pięciu ostatnich trików, wraz ze stopniem pewności modelu co do klasyfikacji triku, wyrażonej w wartości procentowej.

6.4. Integracja modułu TensorFlow Lite z aplikacją

Integrację modeli uczenia maszynowego z kodem aplikacji zrealizowano za pomocą biblioteki `tflite_flutter`, która jest oficjalnym interfejsem do środowiska uruchomieniowego *TensorFlow Lite*. Proces wnioskowania przebiega dwuetapowo:

6.4.1. Estymacja pozy

Na tym etapie przetwarzania danych klasa `MoveNetService` odpowiada za konwersję materiału wideo do lżejszego i łatwiejszego formatu. W pierwszym kroku usługa ładuje model `movenet_thunder.tflite`. Ze względu na duże obciążenie obliczeniowe związane z namierzeniem 17 kluczowych punktów ciała, w konfiguracji interpretera przydzielono 4 wątki procesora. Usługa przetwarza klatki nagrania i zwraca spłaszczoną tablicę 51 wartości, która została opisana dokładniej w rozdziale piątym. Tak spreparowane dane są następnie analizowane.

6.4.2. Klasyfikacja ewolucji

Za klasyfikację ewolucji odpowiada klasa `TrickDetector`. Przygotowany ciąg 30 klatek przekazywany jest do jednowymiarowej splotowej sieci neuronowej, która przechowywana jest w pamięci jako plik binarny `trick_classifier.tflite`. Podczas testów aplikacji na rzeczywistych nagraniach wideo zauważono spadek dokładności klasyfikacji w porównaniu do wyników uzyskanych w środowisku treningowym. Aby poprawić skuteczność rozpoznawania trików bez konieczności ponownego trenowania modelu, w kodzie aplikacji zastosowano dwa mechanizmy wspomagające:

1. **Korekta prawdopodobieństw klas:** Zdefiniowano mapę współczynników korygujących `_baseClassCalibration`, która modyfikuje prawdopodobieństwa wyjściowe zwracane przez sieć. Zwiększa ona wagę dla trików trudniejszych do wykrycia - takich jak *Kickflip*, którego waga wynosi 1.25 - a jednocześnie zmniejsza wagi dla klas, które model skłonny był faworyzować - czyli np. *Frontside 180*, którego waga wynosi 0.88. W poniższym załączniku znajduje się kod tej mapy.

```
1 static const Map<String, double> _baseClassCalibration = {  
2   'Backside180': 0.90,  
3   'Frontside180': 0.88,  
4   'Frontshuvit': 1.08,  
5   'Pressureflip': 0.92,  
6   'Kickflip': 1.25,  
7   'Heelflip': 1.12,
```

```

8  'Ollie': 0.90,
9  'Shuvit': 1.08,
10 };

```

Listing 3. Mapa _baseClassCalibration

2. **Analiza kąta rotacji tułowia:** Zaimplementowano funkcję `_torsoAngle`, widoczną na poniższym załączniku. Oblicza ona kąt nachylenia klatki piersiowej za pomocą funkcji trygonometrycznej $\tan^{-1}$, na podstawie piątego i szóstego punktu kluczowego, czyli odpowiednio lewego oraz prawego ramienia. Obserwując zmiany tego kąta na przestrzeni całego nagrania, aplikacja potrafi określić, czy użytkownik wykonał obrót ciałem w przestrzeni. Pozwala to skutecznie odróżnić triki, w których obraca się tylko deskorolka, takie jak *Shuvit*, od takich, w których obraca się także skater, czyli np. *Frontside 180*.

```

1  double? _torsoAngle(List<double> frame) {
2  if (frame.length < 51) return null;
3
4  // MoveNet keypoints: 5 leftShoulder, 6 rightShoulder.
5  final leftShoulderY = frame[5 * 3];
6  final leftShoulderX = frame[5 * 3 + 1];
7  final leftShoulderS = frame[5 * 3 + 2];
8  final rightShoulderY = frame[6 * 3];
9  final rightShoulderX = frame[6 * 3 + 1];
10 final rightShoulderS = frame[6 * 3 + 2];
11
12 if (leftShoulderS < 0.2 || rightShoulderS < 0.2) return null;
13 return math.atan2(rightShoulderY - leftShoulderY,
14 rightShoulderX - leftShoulderX);
15 }

```

Listing 4. Metoda _torsoAngle

Ostateczna klasyfikacja ewolucji następuje w wyniku syntezy wyjścia z sieci neuronowej z zaprezentowanymi wyżej mechanizmami korekcyjnymi. Proces wyznaczenia wyniku przebiega w następujących krokach:

- Surowe prawdopodobieństwa zwracane przez funkcję *Softmax* dla poszczególnych klas są skalowane (mnożone) przez odpowiadające im wskaźniki z mapy `_baseClassCalibration`.
- Algorytm sumuje całkowitą zmianę kąta tułowia na przestrzeni 30 klatek. Jeżeli wykryty obrót przekracza założony próg geometryczny, priorytetowo traktowane są klasy trików z rotacją ciała, natomiast w przypadku braku rotacji - klasy trików stacjonarnych.
- Z tak zmodyfikowanego wektora prawdopodobieństw wyznaczana jest wartość maksymalna (*argmax*), wskazująca najbardziej prawdopodobną ewolucję.

- Jeżeli obliczona pewność predykcji przekracza przyjęty próg akceptacji (ustalony empirycznie na poziomie 70%), usługa *TrickDetector* zwraca do interfejsu użytkownika nazwę rozpoznanego triku wraz z poziomem ufności wyrażonym w procentach. W przeciwnym razie ewolucja klasyfikowana jest jako nierozpoznana, co zapobiega wyświetlaniu błędnych wyników.

Przekazanie zweryfikowanego wyniku do warstwy prezentacji kończy pełen cykl przetwarzania wideo, umożliwiając natychmiastową prezentację rezultatu na ekranie smartfona.

6.5. Architektura i implementacja warstwy serwerowej

Warstwa serwerowa systemu (nazywana *backendem*), pełni rolę centralnego węzła zarządzającego danymi o infrastrukturze sportowej oraz komunikacją z aplikacją mobilną. Do jej implementacji wykorzystano język *Python* oraz framework *FastAPI*. Wybór tych technologii, opisany szerzej w rozdziale trzecim, podyktowany był wysoce wydajną, asynchroniczną obsługą zapytań, automatyczną walidacją typów danych za pomocą biblioteki *Pydantic* oraz wbudowaną generacją interaktywnej dokumentacji *OpenAPI* (*SwaggerUI*).

Komunikacja między aplikacją mobilną a serwerem odbywa się poprzez bezstanowy interfejs programistyczny *REST API* z wykorzystaniem formatu JSON. Interfejs serwera został podzielony na wyizolowane punkty końcowe, odpowiadające za poszczególne zasoby systemu.

W poniższej tabeli przedstawiono wybrane punkty końcowe *REST API* obsługiwane przez backend:

Tabela 6.1. Przykładowa tabela pokazująca wybrane punkty końcowe REST API.

Metoda HTTP	Ścieżka	Opis funkcjonalny
GET	/spots	Pobranie listy wszystkich „spotów” wraz ze współrzędnymi geograficznymi, opisem, zdjęciami, nazwą, stopniem trudności oraz unikalnym numerem identyfikacyjnym.
POST	/spots	Rejestracja nowego obiektu sportowego przez użytkownika.
PATCH	/spots/{spot_id}	Aktualizacja danych szczegółowych wybranego obiektu, takich jak nazwa, stopień trudności, opis.
DELETE	/spots/{spot_id}	Usunięcie wybranego obiektu z bazy danych.
POST	/spots/{spot_id}/photos	Przesłanie nowego zdjęcia dokumentującego stan techniczny obiektu.

Wykonywanie instrukcji po stronie serwera zostało zabezpieczone przed nieoczekiwanymi błędami. Zapytania zawierające niepoprawne struktury danych (takie jak błędny

format współrzędnych geograficznych) są automatycznie odrzucane z odpowiednim kodem odpowiedzi HTTP (np. 422 Unprocessable Entity), co zapobiega naruszeniu spójności danych oraz ewentualnym błędom w bazie danych.

Aplikacja serwerowa została osadzona w środowisku chmurowym na platformie *Render*. Wykorzystanie kontenerów oraz ciągłej integracji pozwala na automatyczne budowanie i uruchamianie nowej wersji backendu po każdej zmianie w repozytorium kodu.

Jako przykład implementacji, na poniższym załączniku przedstawiono definicję *endpointu* służącego do pobierania szczegółowych danych o obiekcie na podstawie jego identyfikatora. Widoczne jest tu wykorzystanie mechanizmu wstrzykiwania zależności, do uzyskania sesji bazy danych oraz obsługa błędów w przypadku braku żądanego zasobu.

```

1 @app.get("/spots/{spot_id}", response_model=SkateSpotRead)
2 def get_spot(spot_id: int, db: Session = Depends(get_db)) -> SkateSpotRead:
3     spot = (
4         db.query(SkateSpot)
5         .options(selectinload(SkateSpot.photos))
6         .filter(SkateSpot.id == spot_id)
7         .first()
8     )
9     if spot is None:
10         raise HTTPException(status_code=status.HTTP_404_NOT_FOUND,
11                             detail="Spot not found")
12     return _serialize_spot(spot)

```

Listing 5. *Endpoint* get_spot.

6.6. Baza danych oraz przechowywanie zasobów multimedialnych

Do trwałego przechowywania danych o obiektach sportowych oraz danych relacyjnych wykorzystano relacyjną bazę danych *PostgreSQL*. Została ona skonfigurowana w chmurze, co zapewnia ciągłą dostępność zasobów niezależnie od lokalizacji użytkownika.

Struktura bazy danych opiera się na relacyjnym modelu danych. Główna tabela przechowująca informacje o „spotach” zawiera m.in. następujące pola:

- unikalny identyfikator obiektu (id - klucz główny),
- nazwę obiektu oraz kategorię do jakiej się klasyfikuje (np. skatepark, rurka, schody),
- współrzędne geograficzne w postaci wartości zmiennoprzecinkowych,
- poziom trudności (początkujący, średniozaawansowany oraz zaawansowany),
- opcjonalny opis oraz adres obiektu
- znacznik czasu utworzenia oraz modyfikacji.

Strukturę tabeli bazy danych w warstwie aplikacyjnej zdefiniowano za pomocą narzędzia *SQLAlchemy*, co przedstawiono na poniższym załączniku.

```

1 class SkateSpot(Base):
2     __tablename__ = "skate_spots"

```

```
3
4     id: Mapped[int] = mapped_column(Integer, primary_key=True, index=True)
5     name: Mapped[str] = mapped_column(String(120), nullable=False)
6     type: Mapped[str] = mapped_column(String(80), nullable=False)
7     address: Mapped[str] = mapped_column(String(255), nullable=False)
8     latitude: Mapped[float] = mapped_column(Float, nullable=False)
9     longitude: Mapped[float] = mapped_column(Float, nullable=False)
10    description: Mapped[str | None] = mapped_column(Text, nullable=True)
11    difficulty: Mapped[str] = mapped_column(String(32), nullable=False,
12        default="beginner")
13    created_at: Mapped[datetime] = mapped_column(DateTime(timezone=True),
14        default=utc_now, nullable=False)
```

Listing 6. Struktura tabeli bazy danych.

Wysyłanie plików multimedialnych realizowane jest asynchronicznie za pomocą zaimplementowanej klasy adaptera. Na poniższym załączniku przedstawiono fragment logiki odpowiadającej za autoryzację i transfer pliku z serwera do chmurowego magazynu danych.

```
1 async def save(self, upload: UploadFile) -> tuple[str, str]:
2     suffix = Path(upload.filename or "").suffix or ".jpg"
3     file_key = f"spots/{uuid.uuid4().hex}{suffix}"
4     binary = await upload.read()
5
6     upload_url = f"{self._base_url}/storage/v1/object/
7     {self._bucket}/{file_key}"
8     headers = {
9         "apikey": self._service_key,
10        "Authorization": f"Bearer {self._service_key}",
11        "Content-Type": "image/jpeg",
12        "x-upsert": "false",
13    }
14    async with httpx.AsyncClient(timeout=20.0) as client:
15        response = await client.post(upload_url,
16            headers=headers, content=binary)
17
18    public_url = f"{self._base_url}/storage/v1/object/public/
19    {self._bucket}/{file_key}"
20    return upload.filename or file_key, public_url
```

Listing 7. Logika transferu plików.

Przechowywanie zdjęć skateparków dodawanych przez użytkowników zorganizowano w sposób hybrydowy. Same pliki binarne zdjęć nie są zapisywane bezpośrednio w strukturach relacyjnych bazy danych, ponieważ mogłoby to negatywnie wpłynąć na wydajność zapytań. Zamiast tego trafiają one do wydzielonego magazynu plików, a w bazie danych zapisywane są jedynie unikalne identyfikatory oraz adresy URL odwołujące się do konkretnych plików graficznych. Pozwala to na szybkie i lekkie pobieranie struktur JSON przez

aplikację mobilną oraz asynchroniczne dociąganie obrazów w miarę potrzeb interfejsu użytkownika.

Zarówno platforma chmurowa *Render* odpowiadająca za hosting backendu, jak i usługa *Supabase* pełniąca rolę bazy danych i magazynu plików, wykorzystywane są w projekcie w darmowych planach taryfowych. Jest to rozwiązanie w zupełności wystarczające na etapie deweloperskim i testowym. Należy jednak podkreślić, że obie te platformy to wysoce skalowalne, komercyjne usługi chmurowe. Pozwala to na łatwe i błyskawiczne zwiększenie zasobów obliczeniowych (skalowanie wertykalne i horyzontalne) w przypadku przyrostu bazy użytkowników, poprzez przejście na wyższe pakiety subskrypcyjne. Dzięki tak zaprojektowanej architekturze, aplikacja stanowi pełnowymiarowy dowód słuszności koncepcji (z ang. *Proof of Concept* - *PoC*), który może zostać płynnie przekształcony w komercyjny, odporny na duże obciążenia produkt, bez konieczności kosztownego przepisywania kodu infrastruktury.

6.7. Finalny wygląd aplikacji

7. Testy oraz analiza wyników

7.1. Środowisko i scenariusze testowe

7.2. Ewaluacja skuteczności modelu SI

7.3. Testy funkcjonalne aplikacji

7.4. Podsumowanie

7.4.1. Napotkane trudności

7.4.2. Wdrożone poprawki

8. Podsumowanie

8.1. Wnioski z przeprowadzonych prac

8.2. Ograniczenia stworzonego rozwiązania

8.3. Możliwości dalszego rozwoju

Spis rysunków

2.1	Czujnik <i>Skategrounds</i> montowany do podstawy <i>trucka</i> deskorolki, Źródło: skategrounds_tech	14
2.2	Urządzenie <i>Spinnax FREAK</i> oraz dedykowana aplikacja mobilna, Źródło: spinnax_com	15
3.1	Schemat czujnikowej architektury systemu, Źródło: [Opracowanie własne]. . .	22
3.2	Schemat hybrydowej architektury systemu, Źródło: [Opracowanie własne]. . .	23
3.3	Schemat wizyjnej architektury systemu, Źródło: [Opracowanie własne]. . . .	24
4.1	Makieta ekranu mapy aplikacji, Źródło: [Opracowanie własne].	27
4.2	Makieta ekranu detekcji triku aplikacji, Źródło: [Opracowanie własne]. . . .	28
4.3	Makieta ekranu historii trików aplikacji, Źródło: [Opracowanie własne]. . . .	29

Spis tabel

2.1	Porównanie wizyjnej i czujnikowej analizy ruchu w sporcie, Źródło: [opracowanie własne].	18
6.1	Przykładowa tabela pokazująca wybrane punkty końcowe REST API.	40

Spis załączników

1. Nazwa załącznika 1	50
2. Nazwa załącznika 2	52

Załącznik 1. Nazwa załącznika 1

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetur id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

Nam dui ligula, fringilla a, euismod sodales, sollicitudin vel, wisi. Morbi auctor lorem non justo. Nam lacus libero, pretium at, lobortis vitae, ultricies et, tellus. Donec aliquet, tortor sed accumsan bibendum, erat ligula aliquet magna, vitae ornare odio metus a mi. Morbi ac orci et nisl hendrerit mollis. Suspendisse ut massa. Cras nec ante. Pellentesque a nulla. Cum sociis natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Aliquam tincidunt urna. Nulla ullamcorper vestibulum turpis. Pellentesque cursus luctus mauris.

Nulla malesuada porttitor diam. Donec felis erat, congue non, volutpat at, tincidunt tristique, libero. Vivamus viverra fermentum felis. Donec nonummy pellentesque ante. Phasellus adipiscing semper elit. Proin fermentum massa ac quam. Sed diam turpis, molestie vitae, placerat a, molestie nec, leo. Maecenas lacinia. Nam ipsum ligula, eleifend at, accumsan nec, suscipit a, ipsum. Morbi blandit ligula feugiat magna. Nunc eleifend consequat lorem. Sed lacinia nulla vitae enim. Pellentesque tincidunt purus vel magna. Integer non enim. Praesent euismod nunc eu purus. Donec bibendum quam in tellus. Nullam cursus pulvinar lectus. Donec et mi. Nam vulputate metus eu enim. Vestibulum pellentesque felis eu massa.

Quisque ullamcorper placerat ipsum. Cras nibh. Morbi vel justo vitae lacus tincidunt ultrices. Lorem ipsum dolor sit amet, consectetur adipiscing elit. In hac habitasse platea dictumst. Integer tempus convallis augue. Etiam facilisis. Nunc elementum fermentum wisi. Aenean placerat. Ut imperdiet, enim sed gravida sollicitudin, felis odio placerat quam, ac pulvinar elit purus eget enim. Nunc vitae tortor. Proin tempus nibh sit amet nisl. Vivamus quis tortor vitae risus porta vehicula.

Fusce mauris. Vestibulum luctus nibh at lectus. Sed bibendum, nulla a faucibus semper, leo velit ultricies tellus, ac venenatis arcu wisi vel nisl. Vestibulum diam. Aliquam pellentesque, augue quis sagittis posuere, turpis lacus congue quam, in hendrerit risus eros eget felis. Maecenas eget erat in sapien mattis porttitor. Vestibulum porttitor. Nulla facilisi. Sed a turpis eu lacus commodo facilisis. Morbi fringilla, wisi in dignissim interdum, justo lectus sagittis dui, et vehicula libero dui cursus dui. Mauris tempor ligula sed lacus.

Duis cursus enim ut augue. Cras ac magna. Cras nulla. Nulla egestas. Curabitur a leo. Quisque egestas wisi eget nunc. Nam feugiat lacus vel est. Curabitur consectetur.

Suspendisse vel felis. Ut lorem lorem, interdum eu, tincidunt sit amet, laoreet vitae, arcu. Aenean faucibus pede eu ante. Praesent enim elit, rutrum at, molestie non, nonummy vel, nisl. Ut lectus eros, malesuada sit amet, fermentum eu, sodales cursus, magna. Donec eu purus. Quisque vehicula, urna sed ultricies auctor, pede lorem egestas dui, et convallis elit erat sed nulla. Donec luctus. Curabitur et nunc. Aliquam dolor odio, commodo pretium, ultricies non, pharetra in, velit. Integer arcu est, nonummy in, fermentum faucibus, egestas vel, odio.

Sed commodo posuere pede. Mauris ut est. Ut quis purus. Sed ac odio. Sed vehicula hendrerit sem. Duis non odio. Morbi ut dui. Sed accumsan risus eget odio. In hac habitasse platea dictumst. Pellentesque non elit. Fusce sed justo eu urna porta tincidunt. Mauris felis odio, sollicitudin sed, volutpat a, ornare ac, erat. Morbi quis dolor. Donec pellentesque, erat ac sagittis semper, nunc dui lobortis purus, quis congue purus metus ultricies tellus. Proin et quam. Class aptent taciti sociosqu ad litora torquent per conubia nostra, per inceptos hymenaeos. Praesent sapien turpis, fermentum vel, eleifend faucibus, vehicula eu, lacus.

Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Donec odio elit, dictum in, hendrerit sit amet, egestas sed, leo. Praesent feugiat sapien aliquet odio. Integer vitae justo. Aliquam vestibulum fringilla lorem. Sed neque lectus, consectetur at, consectetur sed, eleifend ac, lectus. Nulla facilisi. Pellentesque eget lectus. Proin eu metus. Sed porttitor. In hac habitasse platea dictumst. Suspendisse eu lectus. Ut mi mi, lacinia sit amet, placerat et, mollis vitae, dui. Sed ante tellus, tristique ut, iaculis eu, malesuada ac, dui. Mauris nibh leo, facilisis non, adipiscing quis, ultrices a, dui.

Załącznik 2. Nazwa załącznika 2

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetur id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

Nam dui ligula, fringilla a, euismod sodales, sollicitudin vel, wisi. Morbi auctor lorem non justo. Nam lacus libero, pretium at, lobortis vitae, ultricies et, tellus. Donec aliquet, tortor sed accumsan bibendum, erat ligula aliquet magna, vitae ornare odio metus a mi. Morbi ac orci et nisl hendrerit mollis. Suspendisse ut massa. Cras nec ante. Pellentesque a nulla. Cum sociis natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Aliquam tincidunt urna. Nulla ullamcorper vestibulum turpis. Pellentesque cursus luctus mauris.

Nulla malesuada porttitor diam. Donec felis erat, congue non, volutpat at, tincidunt tristique, libero. Vivamus viverra fermentum felis. Donec nonummy pellentesque ante. Phasellus adipiscing semper elit. Proin fermentum massa ac quam. Sed diam turpis, molestie vitae, placerat a, molestie nec, leo. Maecenas lacinia. Nam ipsum ligula, eleifend at, accumsan nec, suscipit a, ipsum. Morbi blandit ligula feugiat magna. Nunc eleifend consequat lorem. Sed lacinia nulla vitae enim. Pellentesque tincidunt purus vel magna. Integer non enim. Praesent euismod nunc eu purus. Donec bibendum quam in tellus. Nullam cursus pulvinar lectus. Donec et mi. Nam vulputate metus eu enim. Vestibulum pellentesque felis eu massa.

Quisque ullamcorper placerat ipsum. Cras nibh. Morbi vel justo vitae lacus tincidunt ultrices. Lorem ipsum dolor sit amet, consectetur adipiscing elit. In hac habitasse platea dictumst. Integer tempus convallis augue. Etiam facilisis. Nunc elementum fermentum wisi. Aenean placerat. Ut imperdiet, enim sed gravida sollicitudin, felis odio placerat quam, ac pulvinar elit purus eget enim. Nunc vitae tortor. Proin tempus nibh sit amet nisl. Vivamus quis tortor vitae risus porta vehicula.